

Facultad de Ciencias Económicas

Universidad Nacional De Córdoba

Licenciatura en Economía



**Detección de anomalías en la demanda de energía  
eléctrica de Argentina**

Camila Chediack Ciminari

DNI: 41919762

## Introducción

El manejo eficiente del consumo de energía es crucial para el desarrollo sustentable, la protección ambiental y el crecimiento económico, por lo tanto se vuelve necesario predicciones más precisas y un mayor control sobre la demanda de energía. Sin embargo, los patrones de consumo de energía se encuentran sujetos a muchas fuentes de incertidumbre, tales como el clima, el comportamiento de los consumidores y desperfectos técnicos. Estos factores llevan a que se presenten ciertos comportamientos o valores extraños, denominadas en la literatura como “anomalías”, que pueden representar situaciones de robo de electricidad o de fallas, generando un impacto significativo en forma de incremento en los costos, desperdicio de energía o inestabilidad en el sistema, impidiendo que se lleve a cabo una adecuada distribución de la misma.

La detección de anomalías es imprescindible para llevar a cabo una buena gestión en el uso y distribución de la energía, ya que busca identificar eventos inusuales e inesperados en el consumo de energía, con el propósito de accionar con rapidez para mitigar los impactos. Con el avance de la tecnología han surgido nuevas formas de modelar y pronosticar el comportamiento de distintas variables a través del tiempo, entrando en juego los modelos de machine learning y en especial con cierto interés en los modelos Long Short Term Memory (LSTM) por su capacidad para predecir variables aprendiendo a partir de sus patrones a temporales.

El principal objetivo de este trabajo consiste en analizar la implementación de una Red Neuronal LSTM para la predicción y posterior detección de anomalías, con el apoyo del método Nonparametric Dynamic Thresholding, en la Demanda Energética del Mercado Eléctrico Mayorista (MEM) de todo el Sistema Argentino de Interconexión (SADI). Los datos fueron obtenidos de la Compañía Administradora del Mercado Mayorista Eléctrico Sociedad Anónima (CAMMESA), quienes proporcionan datos sobre la demanda horaria de energía eléctrica del mercado energético mayorista, compuesto por los generadores, cogeneradores y autogeneradores como oferentes y por los distribuidores y grandes usuarios como demandantes, quienes dentro de su zona de concesión son las responsables de abastecer a usuarios finales que no tengan la facultad de contratar su suministro en forma independiente. Estas concesiones de distribución son otorgadas por los poderes concedentes de cada área, pudien-

do ser estas Nacionales (como en el caso de EDENOR y EDESUR), Provinciales (EDEA, EPEC, ect) o Municipales (Trelew, Comodoro Rivadavia, etc). Se considera gran usuario a quien contrata de forma independiente y para consumo propio, su abastecimiento de energía eléctrica con el generador o comercializador. En cuanto a los oferentes, los primeros son los que exclusivamente se dedican a la producción de energía eléctrica al MEM, los cogeneradores venden energía eléctrica como un subproducto de su producción y los autogeneradores son aquellas empresas que generan electricidad para autoabastecerse, comercializando sus excedentes o faltantes en el MEM.

En la Argentina, esta industria fue separada en sus tres etapas: generación, transmisión y distribución, con estructuras bien diferenciadas. Por sus características intrínsecas y naturales, el sector de la generación se concibió como un mercado en competencia, mientras que el transporte y la distribución, siendo monopolios naturales, se concesionaron y sometieron a una regulación por incentivos y resultados.

La electricidad, y en consecuencia, la industria encargada de su generación, transmisión y distribución, poseen ciertas características que las distinguen de otros bienes y, por lo tanto, presenta particulares problemas a resolver para una conformación óptima del mercado.

Los altos costos de la energía no suministrada, la aleatoriedad de la demanda, la imposibilidad de almacenar electricidad y, especialmente, las restricciones que impone de la red de transporte (externalidades), requieren la estructuración de mecanismos institucionales de coordinación de las actividades de generación, transmisión y distribución.

La estructura del trabajo comienza con una breve revisión de la bibliografía, donde se señalan las principales y más recientes contribuciones dentro del área de estudio. En segundo lugar se hará una breve descripción sobre los datos utilizados. En tercer lugar se desarrollará sobre la metodología empleada, especificando los hiperparámetros y el tratamiento aplicado a los datos. En cuarto lugar se exhiben los resultados para realizar una breve conclusión al final de este trabajo.

## **Trabajos relacionados**

La energía es un insumo esencial en el modelo de producción junto con el capital, el

trabajo y la tecnología, por lo tanto su suministro a precios asequibles es indispensable para el desarrollo de una economía moderna. Los sectores de energía en los países en desarrollo están caracterizados por un servicio de baja calidad con cortes frecuentes, que no solo perjudica al sector productivo sino que también provocan una disminución en el bienestar de los usuarios. La estructura típica de su mercado energético está conformada por un sector de generación totalmente competitivo y un sector de distribución que opera mediante monopolios naturales.

La falta de inversiones en estos países afecta la capacidad disponible provocando que la generación de energía sea menor a los picos de la demanda, forzando a las empresas a recurrir a prácticas desfavorables como el “load shedding”, un apagón temporario y controlado de energía en algunas áreas específicas para reestablecer el equilibrio entre la oferta y la demanda de energía y prevenir un corte general de energía. Manejar esta situación a través de ajustes tarifarios y aumentos de subsidios hacia las empresas no es la mejor forma de solventar la situación, dado que aumentaría la tentación de robar energía por parte de los consumidores y que las compañías distribuidoras sigan con sus malas prácticas, creándose un círculo vicioso que termina por generar un mayor malestar a los consumidores honestos.

La liberalización o desregularización del mercado energético mediante otorgar autonomía a las empresas encargadas de distribuir la energía e introduciendo la competencia en ese sector, ha sido con la intención de aumentar las inversiones y disminuir las tarifas. Las experiencias demuestran que es un proceso complicado e imposible de llevar a cabo de manera eficiente sin una estructura institucional y política estable. Además, los beneficios en términos de energía confiable y sostenible con tarifas reducidas sólo podrían disfrutarse con una capacidad instalada que supera con creces los picos de la demanda.

Estas reformas, que se han llevado a cabo con éxitos en varias partes del mundo, y los desarrollos de fuentes de energías renovables, ha provocado una creciente volatilidad sobre sus precios futuros y con ello desafíos para quienes toman decisiones día a día sobre futuras inversiones o políticas a implementar. Así como también, planificar la infraestructura necesaria para una demanda que ha ido creciendo un 3%, en los países en desarrollo, con el aumento de los ingresos, la industria y los sectores de servicio, y un 0,7% en los países desarrollados debido a digitalizaciones y electrificaciones (Mir et al., 2020). La mitigación del cambio climático es otra de las motivaciones para mejorar predicción de la demanda dado

que alrededor de un 40 % de las emisiones de CO<sub>2</sub> están directamente relacionadas con la quema de combustibles fósiles para la generación de energía (Bakhtawar Shah, 2019).

Al momento de estimar la demanda de energía eléctrica es fundamental conocer los factores que tiene un mayor impacto sobre la misma y cuáles de todos ellos son los que tienen una mayor incidencia cuando se producen los picos en su consumo. Lin, Gow, y Tsai (2010) expresan que la potencia de energía, los datos de precios históricos y el clima influyen en gran medida, siendo la potencia eléctrica muy afectada por el clima y por lo tanto volviéndola muy volátil frente a sus cambios.

Jamil (2013) identificó una relación empírica entre el robo electricidad, el “load shedding” y el precio de la energía, este estudio fue motivado por la crisis energética en Pakistán y se descubrió que el robo de electricidad tiene un rol fundamental en los cortes de energía y el aumento de tarifas, de modo que es necesario mitigarlo para aumentar la eficiencia en el suministro de energía y disminuir los cortes de energía. El robo de electricidad contribuye al aumento de la demanda de energía más allá de lo esperado o lo planificado, provocando la pérdida de ingresos a las empresas. Identificar este comportamiento anormal facilitaría realizar predicciones de la demanda y mejoraría la planificación del sistema eléctrico.

Dentro de la literatura se encuentran distintos tipos de modelos, los clásicos y un poco obsoletos, son los modelos Autoregressive Integrated Moving Average (ARIMA), lo Generalized Autoregressive Conditional Heteroskedastic (GARCH), Dynamic Regression (DR) y Transfer Functions. Los nuevos métodos incluyen Feed Forward Neural Network (FFNN), Fuzzy Neural Network (FNN), Support Vector Machine (SVR), Long Short-Term Memory (LSTM) o métodos híbridos que combinan estos últimos procedimientos con los clásicos.

En los últimos años la discusión ha girado en torno a demostrar cuál de todos estos nuevos métodos resulta de mayor utilidad para pronosticar la demanda de energía en cada horizonte temporal. En el corto plazo se incluyen pronósticos con horizontes desde unos minutos hasta pocos días para adelante, que resultan esenciales para las operaciones diarias en el mercado. El mediano plazo normalmente son horizontes desde unos pocos días hasta meses adelante y es usualmente preferido para manejo de riesgos, cálculos de hojas de balanzas y valoración de derivados. Luego el largo plazo es usualmente utilizado para la planificación y análisis de rentabilidad sobre las inversiones o adquisición de fuentes de combustible para plantas de

producción, incluye desde unos pocos meses hasta varios años hacia delante.

Predecir la demanda de energía no es una tarea sencilla dado su comportamiento no estacionario, tanto en media como en varianza, y la frecuente presencia de anomalías. Definidas estas últimas como “observaciones que se desvían tanto de las demás observaciones como para despertar sospechas de que fue generado por un mecanismo diferente” (Bakhtawar Shah, 2019 p. 2) y que a su vez estas pueden ser agrupadas en cuatro grandes grupos:

1. *Anomalías Puntuales*: una observación en particular que se desvía del resto de los datos.
2. *Anomalías Contextuales*: aquellas observaciones que son consideradas anomalías dentro de un contexto específico pero caso contrario, son observaciones normales.
3. *Anomalías Colectivas*: son un conjunto de observaciones que de forma individual son normales pero caso contrario son consideradas anomalías.
4. *Anomalías de Cambio de Punto*: este tipo de anomalía se encuentra específicamente en series de datos cuando hay cambios repentinos en los patrones de las obervaciones, es decir, cuando en un momento dado del tiempo hay un cambio de distribución.

En general, los problemas que presentan los modelos clásicos es que no terminan de capturar correctamente su comportamiento no estacionario y por ende no obtienen buenas predicciones. Los modelos híbridos atentaron con compensar la debilidad, Feijoo, Silva, y Das (2016) presentan un modelo híbrido para pronosticar el precio de mercado de la energía eléctrica en tiempo real y para un día después, este enfoque se basa en realizar un modelo de clusterización (utilizando el algoritmo K-means) para luego entrenar los datos por clúster con un modelo SVM. Finalmente, los autores en Mahjoub, Chrifi-Alaoui, Marhic, y Delahoche (2022) destacan el gran avance de la inteligencia artificial con las Recurrent Neural Networks (RNN) y el método de Back-Propagation en redes neuronales, para predecir series de tiempo y que frecuentemente se utilizan en el tratamiento de problemas altamente no lineales a través de una cascada de múltiples capas.

Con este avance en los métodos y gracias a un mayor poder de cómputo, temas relacionados a la predicción de variables resurgen para continuar con este progreso. Es por ello que

la detección de anomalías volvió a llamar la atención de muchos investigadores con el objetivo de prescindir de expertos en el ámbito de estudio para el reconocimiento de anomalías, no solo por ser más costoso sino también por los beneficios que traen los algoritmos para detectarlas en tiempo real y en consecuencia poder actuar de forma más inmediata ante las mismas. Según Hundman, Constantinou, Laporte, Colwell, y Soderstrom (2018) las LSTM ofrecen ciertas ventajas que han motivado su uso dentro de esta tarea de la detección de anomalías, dada su capacidad para modelar funciones no lineales complejas tanto en series temporales univariantes como multivariantes.

### **Mercado Eléctrico Mayorista**

A comienzos de la década del 90, la Argentina se embarcó en una profunda reforma del Estado a partir de la sanción de la Ley N°23.696 que declaró en estado de emergencia la prestación de diversos servicios y llevó a la reestructuración del sector de la energía . A partir del nuevo régimen sancionado en 1992, se crea el Mercado Eléctrico Mayorista a fines de mejorar la eficiencia productiva de todo el sector, el cual se divide en 9 regiones eléctricas integradas por el SADI más Tierra del Fuego, que fue incorporado hace unos años al sistema de forma virtual. El modelo implementado a partir de ese año se basó en la desintegración vertical y horizontal del sector. Se produjo la segmentación de la cadena eléctrica en sus tres componentes básicos: generación, transporte y distribución. La introducción de la competencia directa en la producción, donde el despacho se basa en los costos y son los generadores más eficientes los que producen, fueron algunas de las nuevas reglas en las que se basó esta nueva legislación. Competencia en la producción para los grandes usuarios, quienes pueden contratar libremente sus compras de energía, y en las ampliaciones del sistema de transporte, y la simulación de la competencia en los segmentos regulados, procurando tarifas comparables a los que se obtendrían si el mercado operara bajo un régimen de competencia.

Sin embargo, las características técnicas de la industria eléctrica imponen ciertas restricciones a la introducción absoluta de la competencia en todo el sistema. Dentro de la etapa de distribución, que consiste en suministrar la electricidad a los usuarios finales, la existencia de dos o más empresas distribuidoras en una misma área redundaría en la duplicación de activos y en el posicionamiento final de solo una (Becker, 2020). La existencia de economías de escala hace que sea deseable y más barato la presencia de una única empresa, con la

intervención necesaria del Estado como regulador del servicio, para impedir que esta ejerza su “poder de monopolio”.

La etapa de transporte de la electricidad a muy alto voltaje comprende conectar de manera continua, mediante una red de alta tensión, el productor con el consumidor para proveerle a este último el voltaje requerido en el momento que lo demanda. En este sector se presentan importantes economías de escala, por el uso de una única red y alto costos hundidos, dado que son inversiones específicas sin ningún otro uso económico alternativo.

La regulación del servicio quedó a cargo del Ente Nacional Regulador (ENRE) y de los entes reguladores provinciales. Además, la necesidad de igualar oferta con demanda en forma instantánea por la imposibilidad de almacenar el fluido eléctrico llevan a que se deba operar con un despacho centralizado que determina dónde, quién y cuánto se generará al mismo tiempo. Con la Ley N°24.065 fue creada CAMMESA como una sociedad anónima sin fines de lucro cuyo capital accionario se divide entre las asociaciones que agrupan a los agentes del MEM <sup>1</sup> (poseedoras de un 80 %) y el Estado Nacional representado por la Secretaría de Energía (que posee el 20 % restante). Es la entidad responsable para el manejo y coordinación de todo el sistema a través de una operación planificada que garantice la generación óptima y confiable al menor costo posible, tanto en el corto como en el largo plazo, con funciones de coordinación y despacho técnico del sistema, el establecimiento de los precios mayoristas y la administración de todas las transacciones de energía y potencia entre los actores del mercado. Es fundamental que el sistema acompañe las variaciones de la demanda a lo largo del tiempo, por ende se vuelve necesario una capacidad de producción suficiente para cubrir los picos de demanda y que eso no provoque fallas en el sistema.

En función de la demanda estimada que debe ser satisfecha para un período dado, CAMMESA planifica la generación óptima en base a la disponibilidad de las unidades generadoras, a los combustibles disponibles y a las restricciones en la red de transporte, por lo que a mayor demanda de electricidad se van agregando máquinas que son menos eficientes.

---

<sup>1</sup>AGEERA (Asociación de Generadores de Energía Eléctrica de la República Argentina), ADEERA (Asociación de Distribuidores de Energía Eléctrica de la República Argentina), ATEERA (Asociación de Transportistas de Energía Eléctrica de la República Argentina) y AGUEERA (Asociación de Grandes Usuarios de Energía Eléctrica de la República Argentina).



Actualmente, operan en el MEM 471 generadores, de los cuales 29 son autogeneradores y 7 son cogeneradores, 52 transportistas, 616 distribuidores, que se dividen en 28 distribuidores de Energía, 48 cooperativas eléctricas agentes del MEM, 539 cooperativas no agentes del MEM y un distribuidor menor. Dentro de la demanda conformada en el MEM por los distribuidores, se agregan los Grandes Usuarios con 9091 participantes, donde 371 son Grandes Usuarios Mayores (GUMA), 2193 Grandes Usuarios Menores (GUME), 21 Grandes Usuarios Particulares (GUPA) y 6056 Grandes Usuarios en Distribución Mayores a 300 kW (GUDI).

La generación se concibió como una actividad de interés general, aunque afectada a un servicio público, sometida a condiciones de competencia pero regulada únicamente por temas de interés (cuestiones ambientales) y cuestiones procedimentales (coordinación del despacho, necesidad de minimizar el costo total de producción, necesidad de mantener una reserva, etc). Esta compuesta por los *generadores*, quienes producen y venden energía eléctrica exclusivamente al MEM, los *autogeneradores* cuyo propósito principal es el autoabastecimiento y solo comercia en el MEM sus excedentes o faltantes, y el *cogenerador* que genera conjuntamente energía eléctrica u otra forma de energía para fines industriales y la vende como un subproducto, comerciando sus excedentes o faltantes en el MEM.

El transporte de energía eléctrica es considerado un servicio público por tratarse de un monopolio natural, al presentar economías de escala y grandes costos hundidos, que tiene por objetivo vincular eléctricamente a los generadores con la demanda de energía, ya sea a las distribuidoras o los grandes usuarios. Se trata de una actividad regulada y sujeta a concesión. Tal cual establece la regulación del Mercado Eléctrico Mayorista en Argentina, las empresas Transportistas deben publicar de forma anual y para un horizonte futuro de 8 años, documento que presenten las estadísticas de calidad del sistema de transporte, capacidad y desempeño futuro del mismo y, en función de los resultados, recomendar los nuevos requerimiento de expansión de la red. Cabe destacar que esto no les otorga la responsabilidad de realizar las expansiones pertinentes, quedando esta decisión a criterio de los usuarios de la red, que son quienes financian las inversiones de aumento en la capacidad del sistema.

La Secretaría de Energía del Ministerio de Economía de la Nación destaca en su informe “Lineamientos para el desarrollo integral y sostenible del sector eléctrico al corto y mediano plazo”, que el diseño institucional del mercado no sirvió para incentivar la inversión en la

expansión del sistema de transporte, al no estar acompañado por un mecanismo de planificación global y federal del sistema, provocando la saturación del sistema y volviéndolo un limitante para la incorporación de nueva generación renovable que acompañe las proyecciones de crecimiento de la demanda.

El distribuidor, cuya actividad también ha sido declarada como servicio público dentro de su zona de concesión es responsable de abastecer toda demanda a usuarios finales que no tengan la facultad de contratar un suministro en forma independiente y transmitir toda la energía eléctrica demandada a través de instalaciones conectadas a la red de transporte o generación hasta las instalaciones del usuario. Este subsector presenta una mayor diversidad debido a la heterogeneidad de los mercados de cada provincia, que se encuentran abastecidos por empresas distribuidoras y cooperativas de múltiples tamaños, brindando servicios desde pequeñas localidades hasta la provincia entera. Estas empresas le pagan a CAMMESA un Precio Estacional Estabilizado (PEST) por la energía, dicho precio lo establece (ex-ante) calculado a partir de los promedios semestrales proyectados del mercado spot. El objetivo de esto es mitigar la volatilidad de los precios al constado, y darle una mayor previsibilidad a la tarifa final que se le cobra al usuario.

En conformidad con los principios de la Ley N° 24.065, la regulación de la actividad busca asegurar la prestación de un servicio de calidad a precios razonables. La mayoría de las provincias siguen un esquema similar al regulado por la ley nacional y cuentan con un ente regulador que tiene control sobre la prestación del servicio dentro de su territorio, la calidad del mismo y su regulación tarifaria a través del Valor Agregado de Distribución (VAD), que determina la remuneración del servicio de distribución. No obstante, se han identificado obstáculos que impiden que se cumplan esos requisitos en su totalidad.

Por un lado el PEST es mucho menor al precio monómico, que es el precio de mercado al cual las generadoras cobran la energía que producen, lo que genera un subsidio indirecto a toda la demanda independientemente de las necesidades de cada sector. Por otro lado, aquellas épocas de contracción económica que forzaron a tomar medidas de tarifas máximas o congelamiento de las mismas, provocaron un atraso en el VAD que ha redundado en una disminución de la calidad del servicio, y en muchos casos que las distribuidoras no paguen el PEST de manera completa y a tiempo. El VAD es un factor fundamental para la

sostenibilidad financiera de las empresas distribuidoras, su capacidad de invertir y para el pago por la energía comprada a CAMMESA.

Los distribuidores y los Grandes Usuarios, que se dividen en Grandes Usuarios Mayores (GUMA con una demanda de potencia mayor o igual a 1MW), Grandes Usuarios Menores (GUME con una demanda de potencia entre 0.1 MW y 2 MW) y Grandes Usuarios Particulares (GUPA con una demanda de potencia entre 0.05 MW y 0.1 MW) <sup>2</sup>, pueden celebrar contratos de provisión directamente con los generadores o comercializadores. El comercializador es una nueva figura que aparece dentro de la industria comprando la energía en bloque en el mercado mayorista o a través de contratos bilaterales con los generadores y se la vende al por menor al usuario final, accediendo a las redes de distribución de baja tensión mediante el pago de peajes a los propietarios de las redes.

La organización comercial del MEM se compone de un mercado spot y un mercado a término para la compra y venta de energía, más un sistema de estabilización de precios a los distribuidores. En el *Mercado Spot*, el precio de la energía se fija en forma horaria en función del costo de producción del próximo MWh, es decir que el “precio de mercado” está determinado por el mínimo costo marginal de producir un MWh más para abastecer a la demanda. CAMMESA, en base al costo marginal de producción declarados por los generadores, se encarga de determinar aquellos que van entrando en juego para cubrir la demanda a medida que esta se va manifestando.

Al ser horario, el precio spot es sumamente volátil, ya que depende de factores tan variados como la cantidad de generación por tipo/tecnología, el precio de los combustibles, la tasa de cambio, costos de operación y mantenimiento, costos de incorporación de potencia y energía. Influyen, también, los aportes hidrológicos en las centrales hidráulicas, la indisponibilidad de las máquinas, restricciones en el transporte, las condiciones climáticas, la hora y tipo de día (Stáble, 2011).

En el *Mercado a Término* los agentes productores y demandantes acuerdan contratos de abastecimiento por cantidades, precios y condiciones libremente acordadas por las partes, imponiendo la regulación del MEM exclusivamente condiciones mínimas de información ne-

---

<sup>2</sup>Dentro de esta última categoría se diferencian los GUDI como aquellos que reciben el servicio de algún agente distribuidor

cesarias para su administración y plazo mínimos de duración. El propósito detrás de éstos es dar una mayor estabilidad en el mediano y largo plazo al mercado, al comprometerse los agentes tanto en precios como en cantidades a un determinado suministro (Stábile, 2011).

### **Demanda del Mercado Eléctrico Mayorista del SADI**


La demanda de energía eléctrica se caracteriza por una fuerte estacionalidad, su evolución fluctuante presente de forma diaria, semanal y mensual la hace muy incierta en el corto plazo, debido a que la cantidad demandada de electricidad depende las elecciones de una gran número de usuarios a parte de otro grupo de factores que influyen sobre ella, que también la hacen incierta en el mediano y largo plazo, como los patrones climáticos. Entonces, la demanda eléctrica puede caracterizarse como variable y aleatoria, presentando una fuerte inelasticidad en los momentos picos, dado que se trata de un bien necesario.

Los datos brindados por la página web de CAMMESA contiene valores por hora de la demanda total de energía del MEM para todo el SADI, expresados en megawatts (MWh) y separada en las distintas partes que la conforman, el Gran Usuario MEM, las distribuidoras y las exportaciones. Los datos comprenden desde las cero horas del primero de enero de 2019 hasta las cero horas del treinta y uno de diciembre de 2022, siendo un total de 35064 observaciones, acompañados de información sobre el tipo de día (feriado, hábil, sábado o domingo), el pico de potencia de ese día y la hora en que sucedió, la temperatura media del Gran Buenos Aires y la estación (verano o invierno). A su vez se adicionó información sobre la variación mensual del Estimador Mensual de Actividad Económica (EMAE) y los precios mensuales del mercado energético.


En la Figura 1 es notoria la caída de la demanda de energía casi hasta 0 MWh en el año 2019, que se atribuye al apagón que sufrió todo el país el 16 de Junio de dicho año. Que este hecho se encuentre asentado en los datos, da pautas para creer que las anomalías también se encuentran registradas, a pesar de lo que destacan varios autores dentro del campo de estudio, sobre la falta de este tipo de registros en las bases de datos reales del consumo de energía de muchos países y el problema de trabajar con bases de datos no balanceados. Lo que termina por obligarlos a imputar anomalías de forma sintética o etiquetar ciertos valores identificados como anomalías luego de un exhaustivo análisis, para convertir un problema no supervisado a uno supervisado con la ventaja de poder testear el algoritmos a través

de métricas. El tratamiento de los datos va a ser explicado con mayor detalle en la sección metodológica de este trabajo.

Figura 1: Demanda de Energía Eléctrica



(a) Demanda por hora



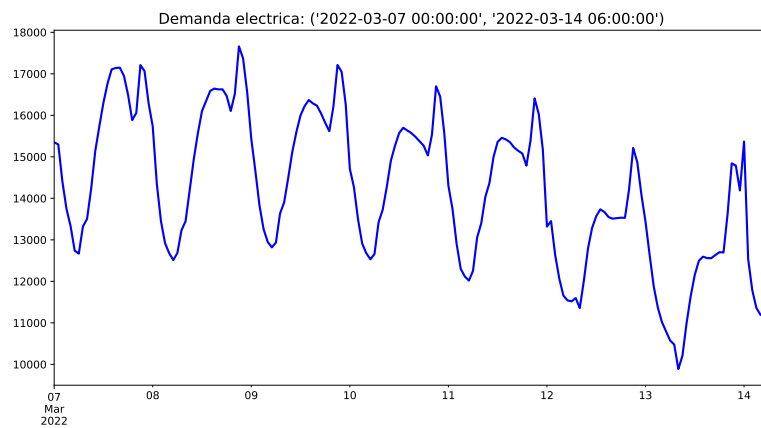
(b) Demanda diaria

*Fuente: Elaboración propia*


La demanda de energía presenta características particulares en las cuáles se incluyen múltiples periodicidades que varían según se analice la serie de forma diaria, semanal o anual. Los autores Shah, Iftikhar, Ali, y Wang (2019) y Bakhtawar Shah (2019) concuerdan que hay patrones semanales y diarios que se repiten en los datos de la demanda de energía eléctrica en la mayoría de los países en el mundo, donde el consumo de energía es mucho

mayor en los días hábiles que en el fin de semana o días feriados, y durante el día hay un aumento constante del consumo hasta llegar a un pico para luego disminuir hasta la mañana del próximo día. Dependiendo del país, estos se producen en distintos horarios, en Argentina por ejemplo suceden en la tarde/noche y a partir de ahí el consumo disminuye hasta las 6 de la mañana que es cuando empieza a aumentar nuevamente, como se ve en la Figura 2.

Figura 2: Demanda de Energía Eléctrica



(a) Durante la semana



(b) Durante el día


*Fuente: Elaboración propia*

Por otro lado, como fue mencionado anteriormente, se trata de series temporales que no tienen media ni varianza constante a través del tiempo, es decir que no es estacionaria. Al realizar una descomposición de la misma en sus tres componentes, tendencia, estacionalidad y residuo, considerando que se trata de un modelo multiplicativo y no aditivo (dada la no

linealidad de su función de demanda), se confirma su no estacionariedad y en consecuencia se transforma la misma para que se vuelva estacionaria. Posteriormente se aplica un test de Dick-Fuller Aumentado para corroborar que la demanda no tuviera raíz unitaria, el resultado muestra que hay evidencia estadística suficiente para rechazar la hipótesis sobre la presencia de raíces unitarias en la variable.

Se sigue con un análisis estadístico de la demanda con el resto de las variables que conforman el conjunto de datos, a fin de indagar la relación entre las mismas y saber si la información que aportan es realmente de calidad y utilidad para estimar demanda de energía eléctrica. En la Figura 3 se presenta la matriz de correlación entre las variables continuas, donde a excepción del pico de potencia, todas las variables muestra una baja correlación con la demanda debido a distintos factores que las afectan.

Figura 3: Matriz de Correlación



*Fuente: Elaboración propia*

Empezando por la temperatura media del GBA y recordando que se trata de la demanda para todo el SADI, esta es poco representativa para un país con un clima tan variado a lo largo del territorio. En estas ocasiones la variable “Estado del Tiempo” es considerada más conveniente se puede debido a que al tratarse de las estaciones del año, puede generalizarse para el resto del país.

En virtud de la estructura que comprende el mercado energético argentino, el modelo que se implementa en el mismo establece que las distribuidoras pueden comprar la energía eléctrica a través de un sistema de Precios Estabilizados Trimestralmente (PEST), que hasta el día de hoy tiene implícito un subsidio significativo para los usuarios y son calculados por el Organismo Encargado del Despacho (en este caso CAMMESA) y aprobados por resolución. Entre tanto, los Grandes Usuarios pagan el Precio Monómico, que se define libremente en el mercado competitivo de la producción de energía.

Con las informaciones obtenidas de las series mensuales de los distintos precios, el PEST y el Precio Monómico, se agregó una tercer variable que es la cobertura tarifaria, resultante de dividir el PEST sobre el Precio Monómico, dado que este último representa el costo de abastecer un MWh adicional a la demanda. Una menor cobertura da a entender un aumento en los costos relacionados a la producción de energía y por ende un aumento de los subsidios implícitos cuando el PEST no acompaña la subida del Precio Monómico.

La estructura y las regulaciones que prevalecen en el MEM, donde la participación de los distribuidores es aproximadamente el 80 %, el precio de mercado y sus derivados no es un gran determinante, quedando claro en la Figura 3 la presente inelasticidad entre el precio y las cantidades demandadas, consecuentemente se excluyen los precios del análisis.

En ocasiones donde las variables no se distribuyen de forma normal o la relación entre las mismas no es lineal, el coeficiente de Pearson (utilizado para reproducir la matriz de correlación) no es el más apropiado y resulta conveniente utilizar un test no paramétrico para capturar la dirección e intensidad de esa relación, como el coeficiente de Kendall tau o el coeficiente de rango de Spearman, siendo preferido el primero por ser mucho más robusto en la presencia de outliers y variables que no se distribuyen de forma normal. Estos indican ausencia de correlación mientras más cercano sea a cero y perfecta correlación positiva o negativa cuando es cercano a 1 o -1 respectivamente.

Al realizar la prueba para las mismas variables de la matriz de correlación, se obtuvieron resultados muy similares, descartando la posibilidad de detectar una relación significativa entre las mismas con la demanda, a excepción del pico de potencia. La presencia de outliers y las demás mencionadas particularidades que presenta la demanda de energía eléctrica, además del hecho de que los datos de la demanda se encuentra por horas y las demás



variables son mensuales, son otros factores que pueden estar afectando los resultados de cualquier análisis estadístico o relación que se quiera encontrar entre las mismas.

Asimismo fue aplicado el test de Dickey Fuller para contrastar la presencia de raíces unitarias, tanto la cobertura tarifaria como el Precio Monómico ponderado Estacional tienen al menos una raíz unitaria y por lo tanto fueron excluidas del análisis junto con todas las variables que parecen tener una relación poco significativa con la demanda.

Con respecto a las variables “Estación” y “Tipo de Día” como son categóricas deben ser tratadas de otra forma para determinar su influencia sobre la demanda de energía. La prueba T-Student sirve para determinar la relación entre una variable categórica y una continua a través de la comparación de las medias de los distintos grupos, es decir que si la diferencia entre las medias de los grupos es estadísticamente significativa, es posible establecer una relación entre las mismas, donde la variable categórica tiene influencia sobre la continua. Particularmente, la diferencia entre las medias de consumo de energía entre las épocas de verano e invierno frente al otoño y la primavera es significativa, los registros máximos históricos de energía y potencia se alcanzan tanto en verano como en invierno debido a las extremas temperaturas, el aumento del uso del aire acondicionado para combatir las olas de calor o el uso intensivo de estufas eléctricas durante el invierno, provocan que haya una mayor cantidad de cortes de luz en esas épocas sobre todo en verano.

Para la variable “Tipo de Día” se separó en dos grupos, los días hábiles y los días no hábiles (sábado, domingo y feriado), obteniendo nuevamente una diferencia significativa entre las medias de los dos grupos, donde en promedio se registra un consumo mayor en los días hábiles, que a su vez va aumentando a lo largo de los años al crecer la necesidad de utilizar cada vez más herramientas tecnológicas para trabajar (impulsado por el aumento de trabajos remotos) y desenvolverse dentro del ámbito académico. A su vez, como estas tareas se frecuentan necesariamente durante una gran parte del día durante la semana laboral, el consumo disminuye durante el fin de semana y los días feriados, que son días donde en general se realizan otras actividades que no necesariamente involucre el uso intensivo de herramientas tecnológicas.

Dados los resultados de la prueba T-Student, las variables categóricas junto con el pico de potencia van a ser las variables a utilizar para estimar la demanda de energía eléctrica,

puesto que estas ejercen una influencia significativa sobre la misma y podrían ser buenas variables predictoras.

## Metodología


Las redes LSTM son un tipo de Red Neuronal Recurrente (RNR) cuya característica principal es que son particularmente útiles para procesar secuencias de datos, a diferencia de otros tipos de Redes Neuronales Artificiales como las Redes Neuronales *feedforward* que procesan los datos de una sola pasada, las RNR están diseñadas para manejar secuencias de datos manteniendo un “memoria” interna que permite realizar un seguimiento de los *inputs* anteriores. La clave en este proceso es su habilidad para pasar información de un paso de la secuencia hacia el siguiente, permitiéndole capturar dependencias temporales en los datos. Cuando esta conexión entre los datos es “cercana”, las RNR aprenden sin problemas. No obstante, a medida que la información relevante para establecer esta relación se aleja entre sí, las RNR se vuelven incapaces de capturar dicha relación. Este problema es conocido como el problema de desaparición del gradiente, que es superado cuando aparecen de las LSTM empleando un mecanismo para prevenir que se almacenen inputs irrelevantes en la “memoria” que la perturben y así permitir un almacenamiento de memoria a largo plazo.

Malhotra, Vig, Shroff, Agarwal, et al. (2015) destacan que gracias a esta habilidad para aprender correlaciones a largo plazo en una secuencia de datos, las LSTM obvian la necesidad de pre-fijar un intervalo temporal, a diferencia de las técnicas tradicionales, y son capaces de modelar adecuadamente secuencias multivariantes complejas. Los procesos de las técnicas tradicionales de monitoreo utilizan medidas como la suma acumulativa (CUSUM) y la Media Móvil Ponderada Exponencialmente (EWMA) dentro de un intervalo de tiempo para detectar los cambios en una distribución. Este intervalo de tiempo se encuentra pre-determinado en base a ciertas características del proceso que está siendo monitoreado y su distribución. El punto es que, este número determina la cantidad del total de observaciones que se van a utilizar para calcular las distintas medidas, en tanto en las LSTM, a pesar de la necesidad de especificar la cantidad de observaciones previas que se van a utilizar para realizar la predicción, a diferencia de las otras técnicas va a utilizar todas las observaciones disponibles de la secuencia para realizar estas predicciones.

En resumen, las Redes Neuronales Recurrentes se pueden entender como varias copias de

una misma red neuronal interconectadas y dispuestas como en una cadena de nodos, donde cada uno de ellos representa un paso específico en el tiempo. Cada output de estos nodos va a ser el input del próximo nodo de la secuencia, como se aprecia en la Figura 4 de una red LSTM, donde los cuadrados amarillos hacen alusión a las capas neuronales de la red, los puntos rosas las operaciones entre vectores y las flechas indican el flujo de la información.


Figura 4: LSTM



Fuente: <https://colah.github.io/posts/2015-08-Understanding-LSTMs/>

La clave en el proceso de las LSTM es la *cell state* que hace fluir la información a lo largo de toda la cadena, y las *hidden states* conformadas por unas estructuras denominadas *gates* encargadas de discernir que información se adiciona o se remueve de la *cell state*.


Figura 5: Cell State LSTM



Fuente: <https://colah.github.io/posts/2015-08-Understanding-LSTMs/>

Estas *gates*, denominadas como *forget gate*, *input gate* y *output gate*, conforman las tres etapas que atraviesan los inputs antes de ser almacenada en la *cell state* para pasar a la siguiente *hidden state*.

Figura 6: LSTM



Fuente: <https://colah.github.io/posts/2015-08-Understanding-LSTMs/>

Como se muestra en la Figura 6 el primer paso es la *forget gate*, donde se decide que información se va a descartar de la *cell state*. Haciendo uso de la función sigmoideal, toma el dato de la *hidden state* anterior más el nuevo dato de entrada y los transforma brindando como resultado un número entre 0 y 1, mientras más cercano a 0 se descarta y mientras más cercano a uno se conserva.

El próximo paso determina la nueva información que debería ser añadida a la *cell state*. Esto incluye una capa, cuyo resultado es un vector compuesto por los datos provenientes de la *forget gate* más los nuevos datos de entrada, que se van a utilizar para actualizar la información contenida en la *cell state*. No obstante, como no toda la información comprendida en este nuevo vector es valiosa, se involucra la *input gate* para filtrar aquellos componentes que valen la pena retener, tratándose de un vector de ceros y unos. El producto punto de estos dos vectores es el que es finalmente añadido a la *cell state*.

Por último se encuentra el *output gate*, que recibe datos provenientes de capas ocultas previas, nuevos datos de entrada y el vector resultante del paso anterior. A estos datos primero se les aplica una función tangente para forzar que sus valores varíen en el rango  $[-1, 1]$  para que luego sean filtrados nuevamente por la función sigmoidea a fin de deshacerse de aquellos datos que no sean útiles y obtener lo que va a ser el input de la nueva *hidden state*.

Las ecuaciones que describen dicho proceso se presentan a continuación:

$$\text{Fogert gate} : f_t = \sigma(W_f[h_{t-1}, x_t] + b_f) \quad (1)$$

$$\text{Input gate} : i_t = \sigma(W_i[h_{t-1}, x_t] + b_i) \quad (2)$$

$$\text{Nuevo candidato} : \tilde{C}_t = \tanh(W_c[h_{t-1}, x_t] + b_c) \quad (3)$$

$$\text{Cell state actualizada} : C_t = f_t * C_{t-1} + i_t * \tilde{C}_t \quad (4)$$

$$\text{Output gate} : o_t = \sigma(W_o[h_{t-1}, x_t] + b_o) \quad (5)$$

$$\text{Output final} : h_t = o_t * \tanh(C_t) \quad (6)$$

Donde  $h_{t-1}$ ,  $x_t$ ,  $b_n$  y  $W_n$  denotan los vectores de input, output, bias (sesgo) y pesos sinápticos para cada tipo de *gate*, con el subíndice  $n$  indicando a cuál de todas ellas se refiere. Luego los outputs de las mismas en el momento  $t$  están señalados por  $f_t$ ,  $i_t$ ,  $o_t$ .

En la implementación de estos modelos debe tenerse en cuenta su arquitectura, su aprendizaje y su capacidad de generalización. Dentro de la arquitectura se deben fijar los hiperparámetros de la red neuronal, en este caso se utilizó la librería KerasTuner<sup>3</sup> para optimizar los hiperparámetros y minimizar el valor de la función de pérdida para el conjunto de validación. El aprendizaje o entrenamiento es el proceso de ajuste de los pesos sinápticos que interconectan las neuronas, para capturar la información que ingresa y así obtener la salida esperada. Finalmente, la capacidad de generalización se refiere al funcionamiento de la red cuando se presentan datos o patrones “desconocidos” que con los que fue entrenada, esperando que sea capaz de seguir extrapolando bien y se consiga un buen ajuste a los datos. Para ello es necesario separar los datos en dos partes, un conjunto de entrenamiento y otro de testeo.

Para llevar a cabo el entrenamiento y el posterior testeo del modelo primero se va a separar el conjunto de datos en tres subconjuntos, uno de entrenamiento que va a abarcar desde el primero de enero del dos mil diecinueve hasta las quince horas del diecinueve de octubre del dos mil veintiuno, un 70 % de todos los datos, del 30 % restante un 10 % va para conjunto de validación y el otro 20 % al conjunto de testeo.


Conforme a lo expresado anteriormente sobre las ventajas de tener las anomalías etique-

---

<sup>3</sup>[https://keras.io/keras\\_tuner/](https://keras.io/keras_tuner/)

tadas y dado que el hecho del 16 de Junio pareciera ser el único registro “extraño” dentro de los datos, que va a estar presente en los datos de entrenamiento junto con las observaciones para el 2020 año que tuvo lugar la pandemia por el Covid-19, se van a imputar anomalías al conjunto de testeo implementando el método propuesto en el trabajo de Turowski et al. (2022). Los autores plantean un modelo para generar distintos tipos de anomalías sintéticas, que fueron derivadas a partir de series de tiempo con datos reales de potencia y energía de distintas partes del mundo, con el fin de desarrollar algoritmos para su detección. Fueron identificados y modelados cuatro tipos de anomalías, el *tipo uno* acontece cuando la energía cae a cero al menos un momento en el tiempo y luego vuelve a subir, el *tipo dos* sucede cuando la energía disminuye y se estanca por varios momentos en el tiempo, el *tipo tres* es una caída repentina de la energía y el *tipo cuatro* un aumento repentino de la energía. Según la clasificación de Bakhtawar Shah (2019) y dependiendo de la duración de la anomalía, se tratan de anomalías puntuales o contextuales como se puede apreciar en la siguiente Figura 7.

Figura 7: Demanda Original vs Demanda con Anomalías



*Fuente: Elaboración propia*

Siguiendo con el tratamiento de los datos, es muy importante primero codificar aquellas variables categóricas para transformarlas en variables numéricas y luego estandarizar todo el conjunto de datos, esto ayuda no sólo a que el modelo entrene más rápido obteniendo mejores resultados en la función de pérdida, sino que en problemas con muchas variables, lo óptimo es que todas ellas se encuentren en la misma unidad de medida (entre rangos de  $[0, 1]$

o  $[-1, 1]$ ) para que el modelo pueda establecer relaciones entre las mismas sin problemas.

El modelo especificado tiene 3 capas LSTM ocultas con 80, 40 y 10 neuronas respectivamente, con un dropout igual a 0.30 para evitar un overfitting y una capa densa con una sola neurona para predecir la demanda de la hora siguiente para seguir con la estructura de los *inputs*, esta capa es la encargada de realizar la transformación final del resultado de las capas LSTM. Se utiliza la función de error cuadrático medio como función de pérdida y el optimizador Adam.

Los *inputs* que reciben todas las redes neuronales están conformados por un lado por  $X$  que hace referencia a todas las variables a utilizar para realizar las predicciones, como si fueran las variables regresoras de una regresión, y por otro lado está la variable  $y$  que es la que se quiere predecir, la variable dependiente. Las LSTM requieren que los datos estén estructurados de una manera específica, estos deben estar dispuestos en pares de  $n$  inputs que se van a utilizar para predecir  $n$  outputs siguientes, es decir, en este caso como se eligió un  $n = 24$  los pares de datos van a estar compuestos por los datos de todo un día de cada una de las variables predictoras (incluida la demanda) para predecir la demanda del próximo día, por lo tanto el conjunto  $X$  de entrenamiento y testeo van a tener 24 valores menos dado que se utilizan las últimas 24 horas para predecir las 24 horas siguientes, mientras que el conjunto  $y$  son los valores de la demanda rezagados por un día. Se entrena la red durante 50 épocas con el parámetro *patience* igual a 10, al igual que el Dropout, este parámetro se utiliza para prevenir el overfitting deteniendo el entrenamiento si no se registran mejoras en la función de pérdida del conjunto de validación durante 10 épocas seguidas.

Para la detección de anomalías se utiliza una adaptación del método planteado en el trabajo de Hundman et al. (2018), Nonparametric Dynamic Thresholding, realizada por Birmingham (2021). Para discernir qué valores del conjunto de datos se tratan de anomalías y cuáles no, este método calcula la secuencia de errores como la diferencia entre las predicciones del modelo LSTM y su verdadero valor. Una vez calculados los errores estos se suavizan con el fin de reducir los picos en los errores que ocurren con frecuencia en las predicciones basadas en LSTM. Los cambios abruptos en los valores a menudo no se predicen perfectamente y dan como resultado picos abruptos en los valores de error, incluso cuando el comportamiento es normal (Hundman et al., 2018). Luego de obtener la serie de

errores suavizada, se elige aquel umbral que, si se eliminan todos los valores por encima de él, causaría el mayor porcentaje de disminución en la media y desviación estándar de los errores suavizados. De esta forma detecta todas las series de errores anómalos, a las cuales les calcula un puntaje  $s$  basado en la distancia entre el error suavizado más alto en cada secuencia de errores anómalos y el umbral elegido, para indicar la gravedad de la anomalía. La razón por la cuál se utiliza esta adaptación es porque ofrece una mayor flexibilidad en la estructura de los datos que se utilizan como *inputs* del algoritmo.

## Resultados


En esta sección del trabajo se exponen primero los resultados obtenidos en el entrenamiento de la red neuronal y al último los resultados de la detección de anomalías.

La LSTM presentada ha demostrado su capacidad para aprender los patrones de la serie y reflejarlos a la hora de predecir no solo datos desconocidos sino que también las anomalías. Es posible que su buen ajuste a estos datos “extraños” se deba a los datos utilizados para entrenarla, aunque estos hayan sido considerados normales, es factible que algunas observaciones presentes, aparte de la destacada en la segunda sección de este trabajo, puedan identificarse como anomalías sobre todo considerando la inclusión del año 2020 dentro del conjunto de entrenamiento.

En un principio se presenta un overfitting en la Figura 8 que se corrige a medida que el modelo aprende lo suficiente sobre el conjunto de entrenamiento como para ser capaz de generalizar ese aprendizaje hacia datos desconocidos alcanzando un error menor en estos último, que son los resultados deseados. Esto se puede detectar a partir del comportamiento de las funciones de pérdida, donde lo que nos indique el overfitting es la ubicación de la función de pérdida del conjunto de validación por encima de la función de pérdida del conjunto de entrenamiento.

Figura 8: Funciones de Pérdida





*Fuente: Elaboración propia*

Al evaluar el modelo con el conjunto de testeo se obtuvo un error cuadrático medio igual a 0,0621, este buen rendimiento en los datos desconocidos se puede evidenciar en la Figura 9, el gráfico en color naranja son los valores reales de la demanda de energía eléctrica proporcionados por CAMMESA, por encima de ese gráfico, en violeta, son los valores que predijo la red entrenada a partir del conjunto de datos que fue reservado para testear su funcionamiento. Las predicciones siguen de forma precisa el patrón de los datos reales, obteniendo solo leves dificultades en aquellos valores más extremos como la caída de energía a 0 MWh donde es notoria la diferencia entre los valores actuales y predichos.


Figura 9: Predicción de la Demanda



*Fuente: Elaboración propia*

En la Figura 10 se realizó una reconstrucción de la demanda donde la parte naranja son los datos que se utilizaron para el entrenamiento de la red neuronal y los datos en color violeta es la predicción de la demanda con la red entrenada. Nuevamente podemos ver que la red es capaz de replicar la demanda de energía eléctrica a pesar de todas sus características y dificultades que fueron presentadas en las secciones anteriores de este trabajo.

Figura 10: Predicción de la Demanda



*Fuente: Elaboración propia*

En promedio por año, la demanda oscila entre unos 14 mil o 15 mil MWh, los datos predichos calculan 15111 MWh de consumo promedio entre Marzo y Diciembre de 2022, considerando el mismo período para los valores actuales la media de consumo es de 15713 MWh, un poco mayor. Cabe destacar que el sector eléctrico está atravesando un momento de transformación donde se verá cada vez más solicitado por las innovaciones tecnológicas en la industria, el transporte y los usos residenciales. El consumo promedio viene aumentando año tras año y superando los récords de máximos históricos de potencia y energía de años anteriores. Los avances acelerados de la tecnología informática, el manejo masivo de datos y los procesos de e-learning e inteligencia artificial le dan un papel cada vez más protagonista a la electricidad, en consecuencia se ha notado un crecimiento en el promedio del consumo de energía año tras año con máximos históricos que también van superando los récords de


años anteriores. Por ello se ha vuelto tan importante poder predecir de forma adecuada la demanda de energía eléctrica para prever su crecimiento y tomar las medidas adecuadas tanto a corto como largo plazo.

En el corto plazo lo más importante es poder prever los picos de demanda para que el sector de generación sea capaz de abastecerlo sin tener que recurrir a malas prácticas para disminuir la demanda de energía por no poseer la capacidad necesaria para enfrentar esos saltos en el consumo, para ello se vuelve muy útil el entrenamiento de algoritmos para detección de anomalías para accionar a tiempo sobre estas situaciones. Es un complemento muy importante para que la predicción de la demanda sea lo más precisa posible, con ayuda de expertos en el tema se podrían identificar los factores que influyen en estos picos y así estar preparados ante inconvenientes. Empleando el algoritmo propuesto para la detección de anomalías se obtuvieron los siguientes valores para las distintas métricas:

<b>Métricas</b>	<b>Resultados</b>
<i>Recall</i>	0.68994
<i>Precision</i>	0.2573
<i>FPR</i>	0.10754
<i>F1 Score</i>	0.3748

Mientras la *Recall* indica el porcentaje de anomalías correctamente predichas sobre el total de las mismas, la *Precision* señala el porcentaje de anomalías correctamente predichas sobre el total de anomalías que fueron reportadas por el algoritmo, *F1 Score* es la media armónica entre la *Precision* y la *Recall*, y por último *FPR* es el porcentaje de anomalías erróneamente predichas sobre el total de no anomalías. En la Figura 11 se exponen los resultados en forma gráfica, el total de anomalías detectadas fue igual a 704 mientras que al conjunto solo fueron imputadas un total de 358, esto nos dice que resultaron muchos falsos positivos (observaciones erróneamente detectadas como anomalías).

Figura 11: Detección de anomalías



*Fuente: Resultado del método NonParametric Dynamic Thresholding*

## Conclusiones

## Referencias

- Bakhtawar Shah, M. (2019). *Anomaly detection in electricity demand time series data*.
- Becker, E. (2020). Análisis del mercado eléctrico argentino. impacto de la regulación en su funcionamiento.
- Burmingham, I. (2021). *multivariate-time-series-anomaly-detection*. [GitHub repository].  
Descargado de <https://github.com/Isaacburmingham/multivariate-time-series-anomaly-detection> (Accessed: February 10, 2023)
- Feijoo, F., Silva, W., y Das, T. K. (2016, 04). A computationally efficient electricity price forecasting model for real time energy markets. *Energy Conversion and Management*, *113*, 27-35. doi: 10.1016/j.enconman.2016.01.043
- Hundman, K., Constantinou, V., Laporte, C., Colwell, I., y Soderstrom, T. (2018). Detecting spacecraft anomalies using lstms and nonparametric dynamic thresholding. En *Proceedings of the 24th acm sigkdd international conference on knowledge discovery & data mining* (pp. 387–395).
- Jamil, F. (2013). On the electricity shortage, price and electricity theft nexus. *Energy policy*, *54*, 267–272.
- Lin, W.-M., Gow, H.-J., y Tsai, M.-T. (2010, 12). Electricity price forecasting using enhanced probability neural network. *Energy Conversion and Management*, *51*, 2707-2714. doi: 10.1016/j.enconman.2010.06.006
- Mahjoub, S., Chrifi-Alaoui, L., Marhic, B., y Delahoche, L. (2022, 05). Predicting energy consumption using lstm, multi-layer gru and drop-gru neural networks. *Sensors*, *22*, 4062. doi: 10.3390/s22114062
- Malhotra, P., Vig, L., Shroff, G., Agarwal, P., y cols. (2015). Long short term memory networks for anomaly detection in time series. En *Esann* (Vol. 2015, p. 89).
- Mir, A. A., Alghassab, M., Ullah, K., Khan, Z. A., Lu, Y., y Imran, M. (2020, 07). A review of electricity demand forecasting in low and middle income countries: The demand determinants and horizons. *Sustainability*, *12*, 5931. doi: 10.3390/su12155931
- Shah, I., Iftikhar, H., Ali, S., y Wang, D. (2019, 07). Short-term electricity demand forecasting using componentsestimation technique. *Energies*, *12*, 2532. doi: 10.3390/en12132532
- Stáble, F. (2011). *Evolución del mercado eléctrico mayorista argentino. impacto de los subsidios en la gestión y en los resultados* (Tesis Doctoral no publicada). Tesis Magister

Universidad Nacional de la Plata, Facultad de Ciencias Económicas.

Turowski, M., Weber, M., Neumann, O., Heidrich, B., Phipps, K., Çakmak, H. K., ... Hagenmeyer, V. (2022). Modeling and generating synthetic anomalies for energy and power time series. En *Proceedings of the thirteenth acm international conference on future energy systems* (pp. 471–484).