

Facultad de Ciencias Económicas

Universidad Nacional De Córdoba

Licenciatura en Economía



**Pronóstico y detección de anomalías en la demanda de
energía eléctrica de Argentina**

Camila Chediack Ciminari

DNI: 41919762

Índice

1. Introducción	1
2. Datos	3
3. Trabajos relacionados	4
4. Mercado Eléctrico Mayorista	9
5. Demanda del Mercado Eléctrico Mayorista	13
6. Metodología	20
7. Resultados	28
8. Conclusiones Preliminares	36
Referencias	38

Índice de figuras

1. Demanda de Energía Eléctrica	14
2. Demanda de Energía Eléctrica	15

3.	Matriz de Correlación	17
4.	LSTM	22
5.	Cell State LSTM	22
6.	LSTM	22
7.	Demanda Original vs Demanda con Anomalías	26
8.	Red Neuronal Feed Forward Multicapa	29
9.	Funciones de Pérdida	31
10.	Predicción de la Demanda	32
11.	Predicción de la Demanda	33
12.	Detección de anomalías	35

Índice de cuadros

1.	Resultados Detección de Anomalías	34
2.	Resultados por Tipo de Anomalías	35

1. Introducción

El manejo eficiente del consumo de energía es crucial para el desarrollo sustentable, la protección ambiental y el crecimiento económico. Por lo tanto, se vuelven necesarias predicciones más precisas y un mayor control sobre la demanda de energía. Sin embargo, los patrones de consumo de energía se encuentran sujetos a muchas fuentes de incertidumbre, tales como el clima, el comportamiento de los consumidores y desperfectos técnicos. Estos factores llevan a que se presenten ciertos comportamientos o valores extraños, denominados en la literatura como “anomalías”, que pueden representar situaciones de robo de electricidad o de fallas, generando un impacto significativo en forma de incremento en los costos, desperdicio de energía o inestabilidad en el sistema, impidiendo que se lleve a cabo una adecuada distribución de la misma.

La detección de anomalías es imprescindible para llevar a cabo una buena gestión en el uso y distribución de la energía, ya que busca identificar eventos inusuales e inesperados en el consumo de electricidad, con el propósito de actuar con rapidez para mitigar los impactos. Con el avance de la tecnología han surgido nuevas formas de modelar y pronosticar el comportamiento de distintas variables a través del tiempo, entrando en juego los modelos de machine learning, siendo particularmente relevantes los modelos Long Short Term Memory (LSTM) por su capacidad para predecir variables aprendiendo a partir de sus patrones temporales.

El principal objetivo de este trabajo consiste en analizar la implementación de una Red Neuronal LSTM para la predicción y posterior detección de anomalías, con el apoyo del método Nonparametric Dynamic Thresholding, en la Demanda Energética del Mercado Eléctrico

Mayorista (MEM) de todo el Sistema Argentino de Interconexión (SADI).

La electricidad y, en consecuencia, la industria encargada de su generación, transmisión y distribución, poseen ciertas características que las distinguen de otros bienes y, por lo tanto, presenta particulares problemas a resolver para una configuración óptima del mercado.

Los altos costos de la energía no suministrada, la aleatoriedad de la demanda, la imposibilidad de almacenar electricidad y, especialmente, las restricciones que impone la red de transporte (externalidades), requieren la estructuración de mecanismos institucionales de coordinación de las actividades de generación, transmisión y distribución. Es por ello, que el principal objetivo de este trabajo es encontrar un método capaz de contribuir en esta tarea de coordinación, de modo que, es importante que sea capaz de brindar estimaciones precisas y detectar outliers. En vista de los resultados obtenidos, el modelo propuesto resulta muy útil para pronosticar la demanda de energía eléctrica en tanto presenta un bajo rendimiento para la detección de anomalías.

La estructura del trabajo comienza con una descripción de los datos utilizados para realizar este trabajo. En segundo lugar, con una breve revisión de la bibliografía, donde se señalan las principales y más recientes contribuciones dentro del área de estudio. En tercer lugar, se hace mención sobre la estructura mercado eléctrico mayorista para caracterizar detalladamente la demanda de energía eléctrica en la cuarta sección. En quinto lugar, se desarrollará sobre la metodología empleada, especificando los hiperparámetros y el tratamiento aplicado a los datos. Por último se exhiben los resultados para realizar una breve conclusión al final de este trabajo.

2. Datos

Los datos fueron obtenidos de la Compañía Administradora del Mercado Mayorista Eléctrico Sociedad Anónima (CAMMESA), quienes proporcionan datos sobre la demanda de energía eléctrica dentro del mercado energético mayorista, compuesto por los generadores, cogeneradores y autogeneradores como oferentes y por los distribuidores y grandes usuarios como demandantes, siendo los distribuidores los responsables de abastecer a usuarios finales, dentro de su zona de concesión, que no tengan la facultad de contratar su suministro en forma independiente. Estas concesiones de distribución son otorgadas por los poderes concedentes de cada área, pudiendo ser estas Nacionales (como en el caso de EDENOR y EDESUR), Provinciales (EDEA, EPEC, ect) o Municipales (Trelew, Comodoro Rivadavia, etc). Se considera gran usuario a quien contrata de forma independiente y para consumo propio su abastecimiento de energía eléctrica con el generador o comercializador.

En la Argentina, esta industria fue separada en sus tres etapas: generación, transmisión y distribución, con estructuras bien diferenciadas. Por sus características intrínsecas y naturales, el sector de la generación se concibió como un mercado en competencia, mientras que el transporte y la distribución, siendo monopolios naturales, se concesionaron y sometieron a una regulación por incentivos y resultados.

Los datos extraídos de la página web de CAMMESA contienen los valores por hora de la demanda total de energía del MEM para todo el SADI desde 2019 hasta 2022, contando con un total de 35064 observaciones, acompañados de información sobre el tipo de día (feriado, hábil, sábado o domingo), el pico de potencia de ese día y la hora en que sucedió, la temperatura media del Gran Buenos Aires y la estación (verano o invierno). A su

vez se adicionó información sobre la variación mensual del Estimador Mensual de Actividad Económica (EMAE) y los precios mensuales del mercado energético.

3. Trabajos relacionados

La energía es un insumo esencial en el modelo de producción de un país, junto con el capital, el trabajo y la tecnología, por lo tanto su suministro a precios asequibles es indispensable para el desarrollo de una economía moderna. Los sectores de energía en los países en desarrollo están caracterizados por un servicio de baja calidad con cortes frecuentes, que no solo perjudica al sector productivo sino que también provocan una disminución en el bienestar de los usuarios. La estructura típica de su mercado energético está conformada por un sector de generación totalmente competitivo y un sector de distribución que opera mediante monopolios naturales.

La falta de inversión en estos países afecta la capacidad disponible provocando que la generación de energía sea menor a los picos de la demanda, forzando a las empresas a recurrir a prácticas desfavorables como el “load shedding”, un apagón temporario y controlado de energía en algunas áreas específicas para reestablecer el equilibrio entre la oferta y la demanda y prevenir un apagón general. Manejar esta situación a través de ajustes tarifarios y aumentos de subsidios hacia las empresas no es la mejor forma de solventar la situación, dado que aumentaría la tentación por parte de los consumidores de robar energía y que las compañías distribuidoras sigan con sus malas prácticas, creándose un círculo vicioso que termina por generar un mayor malestar a los consumidores honestos.

La liberalización o desregularización del mercado energético concediendo autonomía a las

empresas encargadas de distribuir la energía e introduciendo la competencia en ese sector, ha sido con la intención de aumentar las inversiones y disminuir las tarifas. Las experiencias demuestran que es un proceso complicado e imposible de llevar a cabo de manera eficiente sin una estructura institucional y política estable. Además, los beneficios en términos de energía confiable y sostenible con tarifas reducidas sólo podrían disfrutarse con una capacidad instalada que supera con creces los picos de la demanda.

Estas reformas, que se han llevado a cabo con éxito en varias partes del mundo, y los desarrollos de fuentes de energías renovables, han provocado una creciente volatilidad sobre sus precios futuros y con ello desafíos para quienes toman decisiones día a día sobre futuras inversiones o políticas a implementar. Así como también, planificar la infraestructura necesaria para una demanda que ha ido creciendo un 3 %, en los países en desarrollo, con el aumento de los ingresos, la industria y los sectores de servicio, y un 0,7 % en los países desarrollados debido a digitalizaciones y electrificaciones (Mir et al., 2020). La mitigación del cambio climático es otra de las motivaciones para mejorar la predicción de la demanda dado que alrededor de un 40 % de las emisiones de CO₂ están directamente relacionadas con la quema de combustibles fósiles para la generación de energía (Bakhtawar Shah, 2019).

Al momento de estimar la demanda de energía eléctrica es fundamental conocer los factores que tiene un mayor impacto sobre la misma y cuáles de todos ellos son los que tienen una mayor incidencia cuando se producen los picos en su consumo. Lin, Gow, y Tsai (2010) expresan que la potencia de energía, los datos de precios históricos y el clima influyen en gran medida, siendo la potencia eléctrica muy afectada por el clima y por lo tanto volviéndola muy volátil frente a sus cambios.

Jamil (2013) identificó una relación empírica entre el robo de electricidad, el “load shed-

ding” y el precio de la energía, este estudio fue motivado por la crisis energética en Pakistán y se descubrió que el robo de electricidad tiene un rol fundamental en los cortes de energía, dado que contribuye al aumento de la demanda de energía más allá de lo esperado o lo planificado provocando a su vez pérdidas para las empresas, y el aumento de tarifas, de modo que es necesario mitigarlo para aumentar la eficiencia en su suministro y disminuir los cortes. Identificar este comportamiento anormal facilitaría la predicción de la demanda y mejoraría la planificación del sistema eléctrico.

Dentro de la literatura se encuentran distintos tipos de modelos, los clásicos y un poco obsoletos, son los modelos Autoregressive Integrated Moving Average (ARIMA), lo Generalized Autoregressive Conditional Heteroskedastic (GARCH), Dynamic Regression (DR) y Transfer Functions; y los nuevos métodos, que incluyen (entre otros): Feed Forward Neural Network (FFNN), Fuzzy Neural Network (FNN), Support Vector Machine (SVR), Long Short-Term Memory (LSTM) o métodos híbridos que combinan estos últimos procedimientos con los clásicos.

En los últimos años la discusión ha girado en torno a demostrar cuál de todos estos nuevos métodos resulta de mayor utilidad para pronosticar la demanda de energía en cada horizonte temporal. En el corto plazo se incluyen pronósticos con horizontes desde unos minutos hasta pocos días para adelante, que resultan esenciales para las operaciones diarias en el mercado. El mediano plazo normalmente son horizontes desde unos pocos días hasta meses adelante y es usualmente preferido para manejo de riesgos, cálculos de hojas de balances y valoración de derivados. Luego el largo plazo es utilizado para la planificación y análisis de rentabilidad sobre las inversiones o adquisiciones de fuentes de combustible para plantas de producción, incluye desde unos pocos meses hasta varios años hacia adelante. El corto plazo es el horizonte

temporal apropiado para planificar la generación de energía acorde a su demanda, y por lo tanto es el horizonte elegido para realizar este trabajo con un plazo de planificación de un día hacia delante.

Predecir la demanda de energía no es una tarea sencilla dado su comportamiento no estacionario, tanto en media como en varianza, y la frecuente presencia de anomalías. Estas últimas se definen como “observaciones que se desvían tanto de las demás observaciones como para despertar sospechas de que fue generado por un mecanismo diferente” (Bakhtawar Shah, 2019 p. 2) y que a su vez estas pueden ser agrupadas en cuatro grandes grupos:

1. *Anomalías Puntuales*: una observación en particular que se desvía del resto de los datos.
2. *Anomalías Contextuales*: aquellas observaciones que son consideradas anomalías dentro de un contexto específico pero observaciones normales en el caso contrario.
3. *Anomalías Colectivas*: son un conjunto de observaciones que de forma individual son normales pero son consideradas anomalías en el caso contrario.
4. *Anomalías de Cambio de Punto*: este tipo de anomalía se encuentra específicamente en series de datos donde hay cambios repentinos en los patrones de las observaciones, es decir, cuando en un momento dado del tiempo hay un cambio de distribución.

En general, los modelos clásicos no obtienen buenas predicciones porque no capturan correctamente el comportamiento no estacionario de la demanda de energía. Los modelos híbridos intentaron compensar esta debilidad, Feijoo, Silva, y Das (2016) presentan un modelo híbrido para pronosticar el precio de mercado de la energía eléctrica en tiempo real y

para un día después, este enfoque se basa en realizar un modelo de clusterización (utilizando el algoritmo K-means) para luego entrenar los datos por clúster con un modelo SVM. Finalmente, los autores en Mahjoub, Chrifi-Alaoui, Marhic, y Delahoche (2022) destacan el gran avance del “Deep Learning” con las Recurrent Neural Networks (RNN) y el método de Back-Propagation en redes neuronales, para predecir series de tiempo que frecuentemente se utilizan en el tratamiento de problemas altamente no lineales a través de una cascada de múltiples capas. No obstante, las RNN enfrentan el problema de desaparición del gradiente cuando se trata de series temporales muy largas dado que no pueden mantener la conexión entre los datos más recientes con los datos más lejanos, dando lugar a los modelos LSTM que superan este problema con la introducción de una célula de memoria que permite mantener esta conexión entre los datos.

Con este avance en los métodos, producto de un mayor poder de cómputo, a su vez resurgen otros temas estrechamente relacionados a la predicción de variables, entre ellos, la detección de anomalías es uno de los temas que volvió a llamar la atención de muchos investigadores que tenían por objetivo buscar métodos más precisos. Anteriormente el método usual para detectar anomalías en la demanda de energía, y también en otros ámbitos, consistía en buscar personas expertas en el área de estudio para reconocer estas anomalías. Los algoritmos que se conocen hoy en día tienen la ventaja de ser menos costosos y detectar las anomalías en tiempo real, y por consecuencia permite actuar de forma inmediata ante las mismas.

Según Hundman, Constantinou, Laporte, Colwell, y Soderstrom (2018) la Red LSTM heredó ciertas propiedades de las RNN que la hacen una candidata ideal para la detección de anomalías en series de tiempo. Este método tiene la habilidad para preservar y entrenar

las características de los datos, capturando el comportamiento normal de una serie temporal y convirtiéndolo en un modelo robusto para tratar secuencias de datos. Además, tiene capacidad para modelar funciones no lineales complejas, tanto en series temporales univariadas como multivariadas, sin necesidad de reducir la dimensionalidad en este último caso. En los últimos años, estas ventajas han motivado el uso de LSTM en esta tarea de detección de anomalías, utilizando sus predicciones para compararlas con los datos reales y detectar las anomalías presentes en los datos a partir de un conjunto de reglas de detección.

4. Mercado Eléctrico Mayorista

En los países donde la desregulación del mercado eléctrico introdujo una mayor competencia entre sus participantes, surgieron investigaciones como las de Lin et al. (2010), Feijoo et al. (2016) y Ziel y Steinert (2018), que se enfocaron en encontrar un método para pronosticar el precio de la energía eléctrica de forma más precisa, con el objetivo de reducir la incertidumbre sobre sus movimientos futuros para una mejor toma de decisiones.

Por otro lado, métodos para detectar pérdidas de energía (ya sea por consumo fraudulento o fallas en el sistema) es un tema de investigación que es más frecuente en los países en desarrollo, donde el mercado eléctrico está regulado y se enfrentan otro tipo de dificultades. En consecuencia, resulta necesario conocer la estructura de mercado y las variables que más influyen sobre la demanda de energía eléctrica de un país para adecuar los métodos a esas características. Esta sección y la siguiente están abocadas a analizar detalladamente la estructura y funcionamiento del mercado energético de Argentina, particularmente su demanda, para luego tener en cuenta las características de la misma para su pronóstico.

A partir del nuevo régimen sancionado en 1992, se crea el Mercado Eléctrico Mayorista a fines de mejorar la eficiencia productiva de todo el sector. El modelo implementado a partir de ese año se basó en la desintegración vertical y horizontal del sector, lo que produjo la segmentación de la cadena eléctrica en sus tres componentes básicos: generación, transporte y distribución. La introducción de la competencia directa en algunos segmentos o partes de los segmentos de la cadena fueron algunas de las nuevas reglas en las que se basó esta nueva legislación. No obstante, como las características técnicas de la industria eléctrica imponen ciertas restricciones a la introducción absoluta de la competencia en todo el sistema, se implementa una simulación de la competencia en los segmentos regulados, procurando tarifas comparables a los que se obtendrían si el mercado operara bajo un régimen de competencia.

La necesidad de igualar oferta con demanda de forma instantánea, por la imposibilidad de almacenar el fluido eléctrico, lleva a que se deba operar con un despacho centralizado que determina dónde, quién y cuánto se generará al mismo tiempo. Para ello fue creada CAMMESA como entidad responsable para el manejo y coordinación de todo el sistema a través de una operación planificada que garantice la generación óptima y confiable al menor costo posible, tanto en el corto como en el largo plazo, con funciones de coordinación y despacho técnico del sistema, el establecimiento de los precios mayoristas y la administración de todas las transacciones de energía y potencia entre los actores del mercado. Es fundamental que el sistema acompañe las variaciones de la demanda a lo largo del tiempo, por ende se vuelve necesario una capacidad de producción suficiente para cubrir los picos de demanda y que eso no provoque fallas en el sistema.

En función de la demanda estimada que debe ser satisfecha para un periodo dado, CAMMESA planifica la generación óptima en base a la disponibilidad de las unidades generadoras,

a los combustibles disponibles y a las restricciones en la red de transporte, por lo que a mayor demanda de electricidad se van agregando máquinas que son menos eficientes. La generación se concibió como una actividad de interés general, aunque afectada a un servicio público, sometida a condiciones de competencia, pero regulada únicamente por temas de interés (cuestiones ambientales) y cuestiones procedimentales (coordinación del despacho, necesidad de minimizar el costo total de producción, necesidad de mantener una reserva, etc).

La etapa de transporte de la electricidad a muy alto voltaje tiene por objetivo conectar de manera continua, mediante una red de alta tensión, a los generadores con la demanda de energía, ya sea las distribuidoras o los grandes usuarios. Es considerado un servicio público por tratarse de un monopolio natural, al presentar economías de escala y grandes costos hundidos. Se trata de una actividad regulada y sujeta a concesión.

La existencia de economías de escala dentro de la etapa de distribución hace que sea deseable y más barato la presencia de una única empresa, con la intervención necesaria del Estado como regulador del servicio, para impedir que ésta ejerza su “poder de monopolio” (Becker, 2020). El distribuidor, declarado como servicio público dentro de su zona de concesión, es responsable de abastecer toda demanda a usuarios finales que no tengan la facultad de contratar un suministro en forma independiente y transmitir toda la energía eléctrica demandada a través de instalaciones conectadas a la red de transporte o generación hasta las instalaciones del usuario.

Este sector presenta una mayor diversidad debido a la heterogeneidad de los mercados de cada provincia, abastecidos por empresas distribuidoras y cooperativas de múltiples tamaños que brindan sus servicios desde pequeñas localidades hasta la provincia entera. Estas empresas le pagan a CAMMESA un Precio Estacional Estabilizado (PEST) por la energía,

dicho precio es calculado (ex-ante) a partir de los promedios semestrales proyectados del *Mercado Spot*. El objetivo de esto es mitigar la volatilidad de los precios al contado, y darle una mayor previsibilidad a la tarifa final que se le cobra al usuario. La regulación de esta actividad busca asegurar la prestación de un servicio de calidad a precios razonables. El PEST es mucho menor al precio monómico, que es el precio de mercado al cual las generadoras cobran la energía que producen, lo que genera un subsidio indirecto a toda la demanda independientemente de las necesidades de cada sector.

Además del sistema de estabilización de precios a los distribuidores, la organización comercial del MEM se compone de un *Mercado Spot* y un *Mercado a Término* para la compra y venta de energía.

En el *Mercado Spot*, el precio de la energía se fija en forma horaria en función del costo de producción del próximo MWh, es decir, que el “precio de mercado” está determinado por el mínimo costo marginal de producir un MWh más para abastecer a la demanda. CAMMESA, en base al costo marginal de producción declarados por los generadores, se encarga de determinar aquellos que van entrando en juego para cubrir la demanda a medida que esta se va manifestando.

Al ser horario, el precio spot es sumamente volátil, ya que depende de factores tan variados como la cantidad de generación por tipo/tecnología, el precio de los combustibles, la tasa de cambio, costos de operación y mantenimiento y costos de incorporación de potencia y energía. Influyen también, los aportes hidrológicos en las centrales hidráulicas, la indisponibilidad de las máquinas, restricciones en el transporte, las condiciones climáticas, la hora y tipo de día (Stábile, 2011).

En el *Mercado a Término* los agentes productores y demandantes acuerdan contratos de abastecimiento por cantidades, precios y condiciones libremente acordadas por las partes, imponiendo la regulación del MEM exclusivamente en condiciones mínimas de información necesarias para su administración y plazo mínimos de duración.

Mensualmente CAMMESA publica un informe donde describe el comportamiento de las variables relevantes del MEM, exhibiendo el balance de energía con información sobre la demanda y oferta de energía promedio alcanzada ese mes y la evolución de los distintos precios de compra de esa energía.


5. Demanda del Mercado Eléctrico Mayorista

La demanda de energía eléctrica se caracteriza por una fuerte estacionalidad, con una evolución fluctuante presente de forma diaria, semanal y mensual que la hace muy incierta en el corto plazo, debido a que la cantidad demandada de electricidad depende de las elecciones de una gran número de usuarios, además de otro grupo de factores que influyen sobre ella, que también la hacen incierta en el mediano y largo plazo, como los patrones climáticos. Entonces, la demanda eléctrica puede caracterizarse como variable y aleatoria, presentando una fuerte inelasticidad en los momentos picos, por tratarse también de un bien necesario del cual no se puede prescindir.


En la Figura 1 es notoria la caída de la demanda de energía casi hasta 0 MWh en el año 2019, que se atribuye al apagón que sufrió todo el país el 16 de Junio de ese mismo año. Que este hecho se encuentre asentado en los datos, da pautas para creer que las anomalías también se encuentran registradas, a pesar de lo que destacan varios autores dentro del

campo de estudio sobre la falta de este tipo de registros en las bases de datos reales del consumo de energía de muchos países, que a su vez trae el problema de trabajar con bases de datos que no están balanceados. Lo que termina por obligarlos a imputar anomalías de forma sintética o que luego de un exhaustivo análisis se etiqueten ciertos valores que fueron identificados como anomalías, para convertir un problema no supervisado a uno supervisado con todas las ventajas que esto conlleva. El tratamiento de los datos va a ser explicado con mayor detalle en la sección metodológica de este trabajo.

Figura 1: Demanda de Energía Eléctrica



(a) Demanda por hora

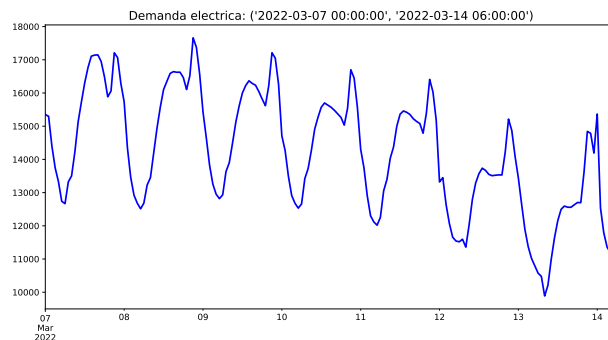


(b) Demanda diaria


Fuente: Elaboración propia en base a datos de Cammesa

Siguiendo con las características particulares de la demanda se incluye las múltiples periodicidades que varían según se analice la serie de forma diaria, semanal o anual. Los autores Shah, Iftikhar, Ali, y Wang (2019) y Bakhtawar Shah (2019) concuerdan que hay patrones semanales y diarios que se repiten en los datos de la demanda de energía eléctrica en la mayoría de los países en el mundo, donde el consumo de energía es mucho mayor en los días hábiles que en el fin de semana o días feriados, y durante el día hay un aumento constante del consumo hasta llegar a un pico para luego disminuir hasta la mañana del próximo día. Dependiendo del país, estos se producen en distintos horarios, en Argentina por ejemplo suceden en la tarde/noche y a partir de ahí el consumo disminuye hasta las 6 de la mañana que es cuando empieza a aumentar nuevamente, como se ve en la Figura 2.

Figura 2: Demanda de Energía Eléctrica



(a) Durante la semana




(b) Durante el día

Fuente: Elaboración propia en base a datos de Cammesa

Como fue mencionado anteriormente, en varias ocasiones, se trata de series temporales que no tienen media ni varianza constante a través del tiempo, es decir que no es estacionaria. Al realizar una descomposición de la misma en sus tres componentes, tendencia, estacionalidad y residuo, considerando que se trata de un modelo multiplicativo y no aditivo (dada la no linealidad de su función de demanda), se confirma su no estacionariedad y en consecuencia se transforma la misma para que se vuelva estacionaria. Posteriormente se aplica un test de Dick-Fuller Aumentado para corroborar que la demanda no tuviera raíz unitaria, el resultado muestra que hay evidencia estadística suficiente para rechazar la hipótesis sobre la presencia de raíces unitarias en la variable. Asimismo fue aplicado el test de Dickey Fuller para contrastar la presencia de raíces unitarias, tanto la cobertura tarifaria como el Precio Monómico ponderado Estacional, resultando en que ambas variables tienen al menos una raíz unitaria.

Continuando con el análisis estadístico, en primera instancia se construye una matriz de correlación con todas las variables continuas del conjunto de datos, para tener una idea inicial sobre el tipo de relación que éstas tienen entre sí. Los valores de los coeficientes de correlación brindan información útil para entender cómo y en qué magnitud, los cambios en una variable pueden impactar en otra. De esta forma se puede identificar de forma rápida aquellas variables más relevantes para estimar la demanda de energía eléctrica y evitar problemas de interdependencia, que surgen al elegir dos variables explicativas altamente correlacionadas. En la Figura 3 se presenta la matriz de correlación entre las variables continuas que muestra que, a excepción del pico de potencia, todas las variables presentan una baja correlación con la demanda debido a distintos factores que las afectan.

Figura 3: Matriz de Correlación



Fuente: Elaboración propia

Empezando por la temperatura media del GBA y recordando que se trata de la demanda para todo el SADI, esta es poco representativa para un país con un clima tan variado a lo largo de todo el territorio. En estas ocasiones la variable “Estado del Tiempo” es considerada más conveniente al tratarse de las distintas estaciones del año, que pueden generalizarse fácilmente para el resto del país.

En virtud de la estructura que comprende el mercado energético argentino, el modelo implementa establece que los distribuidores pueden comprar la energía eléctrica a través de un sistema de Precios Estabilizados Trimestralmente (PEST), que hasta el día de hoy tiene implícito un subsidio significativo para los usuarios. Entre tanto, los Grandes Usuarios pagan el Precio Monómico, que se define libremente en el mercado competitivo de la producción

de energía.

Con las informaciones obtenidas de las series mensuales de los distintos precios, el PEST y el Precio Monómico, se agregó una tercer variable que es la cobertura tarifaria, resultante de dividir el PEST sobre el Precio Monómico, dado que este último representa el costo de abastecer un MWh adicional a la demanda. Una menor cobertura da a entender un aumento en los costos relacionados a la producción de energía y un aumento de los subsidios implícitos cuando el PEST no acompaña la subida del Precio Monómico.

La estructura y las regulaciones que prevalecen en el MEM, donde la participación de los distribuidores es aproximadamente el 80 %, el precio de mercado y sus derivados no es un gran determinante para la estimación de la demanda, quedando claro con la Figura 3 la baja elasticidad entre el precio y las cantidades demandadas, por lo que se excluyen estas variables del análisis.

No obstante, en ocasiones donde las variables no se distribuyen de forma normal o la relación entre las mismas no es lineal, el coeficiente de Pearson (utilizado para reproducir la matriz de correlación) no es el más apropiado y resulta conveniente utilizar un test no paramétrico para capturar la dirección e intensidad de esa relación, como el coeficiente de Kendall tau o el coeficiente de rango de Spearman, siendo preferido el primero por ser mucho más robusto en la presencia de outliers y variables que no se distribuyen de forma normal. Estos indican ausencia de correlación mientras más cercano sea a cero y perfecta correlación positiva o negativa cuando es cercano a 1 o -1 respectivamente.

Al realizarse una segunda prueba para las mismas variables de la matriz de correlación con el coeficiente de Kendall tau, se obtienen resultados muy similares, descartando la posibilidad

de detectar una relación significativa entre las mismas con la demanda, a excepción del pico de potencia. La presencia de outliers y las demás mencionadas particularidades que presenta la demanda de energía eléctrica, además del hecho de que los datos agregados son mensuales y la demanda se encuentra por horas, son otros factores que pueden estar afectando los resultados de cualquier análisis estadístico o relación que se quiera encontrar entre las mismas.

Con respecto a las variables “Estación” y “Tipo de Día” como son categóricas deben ser tratadas de otra forma para determinar su influencia sobre la demanda de energía. La prueba T-Student sirve para determinar la relación entre una variable categórica y una continua a través de la comparación de las medias de los distintos grupos, es decir que si la diferencia entre las medias de los grupos es estadísticamente significativa, es posible establecer una relación entre las mismas, donde la variable categórica tiene influencia sobre la continua. Particularmente, la diferencia entre las medias de consumo de energía entre las épocas de verano e invierno frente al otoño y la primavera es significativa, los registros máximos históricos de energía y potencia se alcanzan tanto en verano como en invierno debido a las extremas temperaturas, que llevan a un aumento del uso del aire acondicionado para combatir las olas de calor o el uso intensivo de estufas eléctricas durante el invierno, provocando una mayor cantidad de cortes de luz en esas épocas sobre todo en verano.

Para la variable “Tipo de Día” se separó en dos grupos, los días hábiles y los días no hábiles (sábado, domingo y feriado), obteniendo nuevamente una diferencia significativa entre las medias de los dos grupos, donde en promedio se registra un consumo mayor en los días hábiles, que a su vez va aumentando a lo largo de los años al crecer la necesidad de utilizar cada vez más herramientas tecnológicas para trabajar (impulsado por el aumento de trabajos remotos) y desenvolverse dentro del ámbito académico. A su vez, como estas tareas

se frecuentan necesariamente durante una gran parte del día durante la semana laboral, el consumo disminuye durante el fin de semana y los días feriados, que son días donde en general se realizan otras actividades que no necesariamente involucra el uso intensivo de herramientas tecnológicas.

Dados los resultados de la prueba T-Student, las variables categóricas junto con el pico de potencia van a ser las variables a utilizar para estimar la demanda de energía eléctrica, puesto que estas ejercen una influencia significativa sobre la misma y podrían ser buenas variables predictoras.

6. Metodología


Las redes LSTM son un tipo de Red Neuronal Recurrente (RNR) cuya característica principal es que son particularmente útiles para procesar secuencias de datos, a diferencia de otros tipos de Redes Neuronales Artificiales como las Redes Neuronales *feedforward* que procesan los datos de una sola pasada, las RNR están diseñadas para manejar secuencias de datos manteniendo una “memoria” interna que permite realizar un seguimiento de los *inputs* anteriores. La clave en este proceso es su habilidad para pasar información de un paso de la secuencia hacia la siguiente, permitiéndole capturar dependencias temporales en los datos. Cuando esta conexión entre los datos es “cercana”, las RNR aprenden sin problemas. No obstante, a medida que la información relevante para establecer esta relación se aleja entre sí, las RNR se vuelven incapaces de capturar dicha relación. Este problema es conocido como el problema de desaparición del gradiente, que es superado cuando aparecen las LSTM empleando un mecanismo para prevenir que se almacenen inputs irrelevantes que perturben

la “memoria”.

Malhotra, Vig, Shroff, y Agarwal (2015) destacan que gracias a esta habilidad para aprender correlaciones a largo plazo en una secuencia de datos, con las LSTM no es necesario pre-fijar un intervalo temporal, a diferencia de las técnicas tradicionales, y son capaces de modelar adecuadamente secuencias multivariantes complejas. Los procesos de las técnicas tradicionales de monitoreo utilizan medidas como la suma acumulativa (CUSUM) y la Media Móvil Ponderada Exponencialmente (EWMA) dentro de un intervalo de tiempo para detectar los cambios en una distribución. El punto es que, este número determina la cantidad del total de observaciones que se van a utilizar para calcular las distintas medidas, CUSUM y EWMA, en tanto en las LSTM, a pesar de la necesidad de especificar la cantidad de observaciones previas que se van a utilizar para realizar la predicción, la diferencia con las otras técnicas se encuentra en que va a utilizar el resto de las observaciones disponibles de la secuencia para realizar las predicciones.

En resumen, las Redes Neuronales Recurrentes se pueden entender como varias copias de una misma red neuronal interconectadas y dispuestas como en una cadena de nodos, donde cada uno de ellos representa un paso específico en el tiempo. Cada output de estos nodos va a ser el input del próximo nodo de la secuencia, como se aprecia en la Figura 4 de una red LSTM, donde los cuadrados amarillos hacen alusión a las capas neuronales de la red, los puntos rosas las operaciones entre vectores y las flechas indican el flujo de la información.


Figura 4: LSTM



Fuente: <https://colah.github.io/posts/2015-08-Understanding-LSTMs/>

La clave en el proceso de las LSTM es la *cell state* que hace fluir la información a lo largo de toda la cadena, y las *hidden states* conformadas por unas estructuras denominadas *gates* encargadas de discernir que información se adiciona o se remueve de la *cell state*.


Figura 5: Cell State LSTM



Fuente: <https://colah.github.io/posts/2015-08-Understanding-LSTMs/>

Estas *gates*, denominadas como *forget gate*, *input gate* y *output gate*, conforman las tres etapas que atraviesan los inputs antes de ser almacenados en la *cell state* para pasar a la siguiente *hidden state*.

Figura 6: LSTM



Fuente: <https://colah.github.io/posts/2015-08-Understanding-LSTMs/>

Como se muestra en la Figura 6 el primer paso es la *forget gate*, donde se decide que información se va a descartar de la *cell state*. Haciendo uso de la función sigmoideal, toma el dato de la *hidden state* anterior más el nuevo dato de entrada y los transforma brindando como resultado un número entre 0 y 1, mientras más cercano a 0 se descarta y mientras más cercano a uno se conserva.

El próximo paso determina la nueva información que debería ser añadida a la *cell state*. Esto incluye una capa, cuyo resultado es un vector compuesto por los datos provenientes de la *forget gate* más los nuevos datos de entrada, que se van a utilizar para actualizar la información contenida en la *cell state*. No obstante, como no toda la información comprendida en este nuevo vector es valiosa, se involucra la *input gate* para filtrar aquellos componentes que valen la pena retener, tratándose de un vector de ceros y unos. El producto punto de estos dos vectores es el que es finalmente añadido a la *cell state*.

Por último se encuentra el *output gate*, que recibe datos provenientes de capas ocultas previas, nuevos datos de entrada y el vector resultante del paso anterior. A estos datos

primero se les aplica una función tangente para forzar que sus valores varíen en el rango $[-1, 1]$ para que luego sean filtrados nuevamente por la función sigmoidea a fin de deshacerse de aquellos datos que no sean útiles y obtener lo que va a ser el input de la nueva *hidden state*.

Las ecuaciones que describen dicho proceso se presentan a continuación:

$$\text{Forget gate : } f_t = \sigma(W_f[h_{t-1}, x_t] + b_f) \quad (1)$$

$$\text{Input gate : } i_t = \sigma(W_i[h_{t-1}, x_t] + b_i) \quad (2)$$

$$\text{Nuevo candidato : } \tilde{C}_t = \tanh(W_c[h_{t-1}, x_t] + b_c) \quad (3)$$

$$\text{Cell state actualizada : } C_t = f_t * C_{t-1} + i_t * \tilde{C}_t \quad (4)$$

$$\text{Output gate : } o_t = \sigma(W_o[h_{t-1}, x_t] + b_o) \quad (5)$$

$$\text{Output final : } h_t = o_t * \tanh(C_t) \quad (6)$$

Donde h_{t-1} , x_t , b_n y W_n denotan los vectores de input, output, bias (sesgo) y pesos sinápticos para cada tipo de *gate*, con el subíndice n indicando a cuál de todas ellas se refiere. Luego los outputs de las mismas en el momento t están señalados por f_t , i_t , o_t .

En la implementación de estos modelos debe tenerse en cuenta su arquitectura, su aprendizaje y su capacidad de generalización. Dentro de la arquitectura se deben fijar los hiperparámetros de la red neuronal, en este caso se utilizó la librería KerasTuner ¹ para optimizar los hiperparámetros y minimizar el valor de la función de pérdida para el conjunto de validación. El aprendizaje o entrenamiento es el proceso de ajuste de los pesos sinápticos que interconectan las neuronas, para capturar la información que ingresa y así obtener la salida esperada. Finalmente, la capacidad de generalización se refiere al funcionamiento de la red

¹https://keras.io/keras_tuner/


cuando se presentan datos o patrones “desconocidos” que con los que fue entrenada, esperando que sea capaz de seguir extrapolando bien y se consiga un buen ajuste a los datos. Para ello es necesario separar los datos en dos partes, un conjunto de entrenamiento, validación y otro de testeo.

Para llevar a cabo el entrenamiento y el posterior testeo del modelo primero se va a separar el conjunto de datos en los tres subconjuntos, uno de entrenamiento que va a abarcar desde el primero de enero del dos mil diecinueve hasta las quince horas del diecinueve de octubre del dos mil veintiuno, un 70 % de todos los datos, del 30 % restante un 10 % va para conjunto de validación y el otro 20 % al conjunto de testeo.

Conforme a lo expresado anteriormente sobre las ventajas de tener las anomalías etiquetadas y dado que el hecho del 16 de Junio pareciera ser el único registro “extraño” dentro de los datos, que va a estar presente en los datos de entrenamiento junto con las observaciones para el 2020 año que tuvo lugar la pandemia por el Covid-19, se van a añadir anomalías al conjunto de testeo implementando el método propuesto en el trabajo de Turowski et al. (2022). Estos autores plantean un modelo para generar distintos tipos de anomalías sintéticas, que fueron derivadas a partir de series de tiempo con datos reales de potencia y energía de distintas partes del mundo, con el fin de desarrollar algoritmos para su detección. Fueron identificados y modelados cuatro tipos de anomalías, el *tipo uno* acontece cuando la energía cae a cero al menos un momento en el tiempo y luego vuelve a subir, el *tipo dos* sucede cuando la energía disminuye y se estanca por varios momentos en el tiempo, el *tipo tres* es una caída repentina de la energía por varios momentos en el tiempo y el *tipo cuatro* un aumento repentino de la energía. Según la clasificación de Bakhtawar Shah (2019) y dependiendo de la duración de la anomalía, se tratan de anomalías puntuales o contextuales. En la Figura

7 se realiza una comparación entre la demanda original antes y después de añadirle las anomalías, en celeste se tiene la demanda original y en rojo es la demanda luego de añadirle las anomalías generadas.

Figura 7: Demanda Original vs Demanda con Anomalías



Fuente: Elaboración propia

Siguiendo con el tratamiento de los datos, es muy importante primero codificar aquellas variables categóricas para transformarlas en variables numéricas mediante algún método de *encoding* y luego estandarizar todo el conjunto de datos, esto ayuda no sólo a que el modelo entrene más rápido obteniendo mejores resultados en la función de pérdida, sino que en problemas con muchas variables, lo óptimo es que todas ellas se encuentren en la misma unidad de medida (entre rangos de $[0, 1]$ o $[-1, 1]$) para que el modelo pueda establecer relaciones entre las mismas sin problemas y de forma más rápida.

El modelo especificado tiene 3 capas LSTM ocultas con 80, 40 y 10 neuronas respectivamente, con un dropout igual a 0.30 para evitar un overfitting y una capa densa con una sola neurona para predecir la demanda de la hora siguiente para seguir con la estructura de los *inputs*, esta capa es la encargada de realizar la transformación final del resultado de las

capas LSTM. Se utiliza la función de error cuadrático medio como función de pérdida y el optimizador Adam.

Los *inputs* que reciben todas las redes neuronales están conformados por un lado por X que hace referencia a todas las variables a utilizar para realizar las predicciones, como si fueran las variables regresoras en un problema de regresión, y por otro lado está la variable y que es la que se quiere predecir, la variable dependiente. En este caso la variable dependiente, que es la demanda de energía eléctrica del MEM, también forma parte de las variables explicativas junto al pico de potencia, el tipo de día y la estación del año. La diferencia es que los valores rezagados de la demanda, es decir sus valores históricos, se utilizan como variables explicativas de la demanda.

Las LSTM requieren que los datos estén estructurados de una manera específica, estos deben estar dispuestos en pares de n inputs que se van a utilizar para predecir los n outputs siguientes, es decir, en este caso como se eligió un $n = 24$ los pares de datos van a estar compuestos por los datos de todo un día de cada una de las variables predictoras (incluida la demanda) para predecir la demanda del próximo día, por lo tanto el conjunto X de entrenamiento y testeo van a tener 24 valores menos dado que se utilizan las últimas 24 horas para predecir las 24 horas siguientes, mientras que el conjunto y son los valores de la demanda rezagados por un día. Se entrena la red durante 50 épocas con el parámetro *patience* igual a 10, al igual que el Dropout, este parámetro se utiliza para prevenir el overfitting deteniendo el entrenamiento si no se registran mejoras en la función de pérdida del conjunto de validación durante 10 épocas seguidas.

La detección de anomalías se realiza mediante una adaptación del método planteado en el trabajo de Hundman et al. (2018), Nonparametric Dynamic Thresholding, realizada por

Burmingham (2021). Los autores proponen un método no supervisado que alcanza un alto rendimiento con bajo costo y sin el uso de datos etiquetados o suposiciones estadísticas sobre los errores.


Para distinguir qué valores del conjunto de datos se tratan de anomalías y cuáles no, este método calcula una secuencia de los errores, que se obtienen de la diferencia entre la predicción del modelo y su verdadero valor. Una vez calculados, estos errores se suavizan con el fin de reducir los picos en los errores que ocurren con frecuencia en las predicciones basadas en LSTM. Los cambios abruptos en las series a menudo no se predicen perfectamente y dan como resultado errores bastante altos, incluso cuando el comportamiento es normal Hundman et al. (2018). Luego de obtener la serie de errores suavizada, se elige aquel umbral que, eliminando todos los valores por encima de él, causaría el mayor porcentaje de disminución en la media y desviación estándar de los errores suavizados. De esta forma detecta todas las series de errores anómalos, a las cuales les calcula un puntaje s basado en la distancia entre el error suavizado más alto en cada secuencia de errores anómalos y el umbral elegido, para indicar la gravedad de la anomalía. La razón por la cuál se utiliza esta adaptación del algoritmo es porque ofrece una mayor flexibilidad en la estructura de los datos que se utilizan como *inputs*.

7. Resultados

En esta sección del trabajo se exponen primero los resultados obtenidos en el entrenamiento de la red neuronal, realizando una comparación con una red neuronal multicapa, y al último los resultados de la detección de anomalías.

Al realizar las primeras pruebas con una red neuronal multicapa y utilizando las mismas variables como inputs, los resultados de las predicciones resultaron ser bastante pobres. Los motivos por lo cuales esto puede llegar a suceder es que este tipo de redes neuronales tienen una capacidad limitada para manejar dependencias a largo plazo, lo que lleva a este mal rendimiento en la predicción de valores futuros. El principal inconveniente durante el entrenamiento fue que en ningún momento se logra superar el overfitting, si bien los valores alcanzados tanto por la función de pérdida del conjunto de entrenamiento como la del conjunto de validación fueron bajos, esta última estuvo por encima de la primera en todo momento. Este problema se presenta frecuentemente dado que este tipo de redes suele sobreajustar fácilmente, lo que significa que memoriza los datos de entrenamiento en lugar de aprender los patrones subyacentes y como resultado se obtiene una generalización deficiente.

Figura 8: Red Neuronal Feed Forward Multicapa



Fuente: Elaboración propia

En la Figura 8 donde las predicciones están en color azul vemos como puede seguir la tendencia de la demanda en todo el tramo pero no puede captar la frecuente volatilidad de la misma. En el largo plazo no hay una tendencia demasiado pronunciada sobre la demanda


promedio de la energía eléctrica, la cual ha ido variando aproximadamente un 4 % de un año al otro en los cuatro años considerados para realizar este trabajo, la mayor variación se produjo del año 2020 al año 2021 por razones que son de público conocimiento.

La LSTM presentada ha demostrado su capacidad para aprender los patrones de la serie y reflejarlos a la hora de predecir no solo datos desconocidos sino también las anomalías. Es posible que su buen ajuste a estos datos “extraños” se deba a los datos utilizados para entrenarla, aunque estos hayan sido considerados normales, es factible que algunas observaciones presentes, aparte de la destacada en la segunda sección de este trabajo, puedan identificarse como anomalías sobre todo considerando que se incluyó el año 2020 dentro del conjunto de entrenamiento.

El desempeño de una red neuronal se mide a través de las funciones de pérdida, como se ven en la Figura 9. Esta tendencia decreciente de la función de pérdida del conjunto de entrenamiento (la línea azul) se debe a que, el modelo aprendió durante el entrenamiento logrando mejorar sus predicciones y por consiguiente, disminuyendo el error entre sus predicciones y los verdaderos valores. Por otro lado, la función de pérdida del conjunto de validación (la línea naranja) provee una medida del desempeño del modelo en datos “desconocidos”, por lo tanto su comportamiento decreciente es en virtud de que es capaz de generalizar su aprendizaje a datos con los que no fue entrenada. Cuando el modelo tiene un buen desempeño en los datos de entrenamiento pero un mal desempeño en los datos de validación, se debe a que hay un overfitting, como el que está presente en las primeras épocas de la Figura 9 donde la función de validación está por encima de la función de entrenamiento, y el cual se corrige a medida que el modelo aprende lo suficiente sobre el conjunto de entrenamiento como para ser capaz de generalizar ese aprendizaje hacia datos desconocidos, alcanzando los resultados

deseados con un error menor en las últimas etapas.


Figura 9: Funciones de Pérdida



Fuente: Elaboración propia

Al evaluar el modelo con el conjunto de testeo se obtuvo un error cuadrático medio igual a 0,0621; este buen rendimiento en los datos desconocidos se puede evidenciar en la Figura 10: el gráfico en color naranja son los valores reales de la demanda de energía eléctrica proporcionados por CAMMESA, por encima de ese gráfico, en violeta, son los valores que predijo la red entrenada a partir del conjunto de datos que fue reservado para testear su funcionamiento. Las predicciones siguen de forma precisa el patrón de los datos reales, obteniendo solo leves dificultades en aquellos valores más extremos como la caída de energía a 0 MWh donde es notoria la diferencia entre los valores actuales y predichos.


Figura 10: Predicción de la Demanda



Fuente: Elaboración propia

En la Figura 11 se realizó una reconstrucción de la demanda donde la parte naranja son los datos que se utilizaron para el entrenamiento de la red neuronal y los datos en color violeta es la predicción de la demanda con la red entrenada. Nuevamente podemos ver que la red es capaz de replicar la demanda de energía eléctrica a pesar de todas las características y dificultades que fueron presentadas en las secciones anteriores de este trabajo.

Figura 11: Predicción de la Demanda



Fuente: Elaboración propia

En promedio por año, la demanda oscila entre unos 14 mil o 15 mil MWh, los datos predichos calculan 15111MWh de consumo promedio entre Marzo y Diciembre de 2022, considerando el mismo período para los valores reales, la media de consumo es de 15713MWh, un poco mayor. Cabe destacar que el sector eléctrico está atravesando un momento de transformación donde se verá cada vez más solicitado por las innovaciones tecnológicas en la industria, el transporte y los usos residenciales. Los avances acelerados de la tecnología informática, el manejo masivo de datos y los procesos de e-learning e inteligencia artificial le dan un papel cada vez más protagonista a la electricidad, en consecuencia se ha notado un crecimiento en el promedio del consumo de energía año tras año con máximos históricos que también van superando los récords de años anteriores. Por ello se ha vuelto tan importante poder predecir de forma adecuada la demanda de energía eléctrica para prever su crecimiento y tomar las medidas adecuadas tanto a corto como largo plazo.

En el corto plazo lo más importante es poder preveer los picos de demanda para que el sector de generación sea capaz de abastecerlo sin tener que recurrir a malas prácticas para disminuir la demanda de energía por no poseer la capacidad necesaria para enfrentar esos saltos en el consumo, para ello se vuelve muy útil el entrenamiento de algoritmos para detección de anomalías para accionar a tiempo sobre estas situaciones. Es un complemento muy importante para que la predicción de la demanda sea lo más precisa posible, con ayuda de expertos en el tema se podrían identificar los factores que influyen en estos picos y así estar preparados ante inconvenientes. Empleando el algoritmo propuesto para la detección de anomalías se obtuvieron los siguientes valores para las distintas métricas:

Cuadro 1: Resultados Detección de Anomalías


Métricas	Resultados
<i>Recall</i>	0.3791
<i>Precision</i>	0.2266
<i>FPR</i>	0.1419
<i>F1 Score</i>	0.2837

Fuente: Elaboración propia.

Mientras la *Recall* indica el porcentaje de anomalías correctamente predichas sobre el total de las mismas, la *Precision* señala el porcentaje de anomalías correctamente predichas sobre el total de anomalías que fueron reportadas por el algoritmo, *F1 Score* es la media armónica entre la *Precision* y la *Recall*, y por último *FPR* es el porcentaje de anomalías erróneamente predichas sobre el total de no anomalías. Es decir que, de todas las anomalías encontradas solo el 18 % de ellas están correctamente etiquetadas, estas anomalías correcta-

mente etiquetadas representan el 36 % del total de las anomalías presentes en el conjunto de testeo.

Figura 12: Detección de anomalías



Fuente: Resultado del método NonParametric Dynamic Thresholding

En la Figura 12 se muestra la demanda proyectada por el modelo LSTM en celeste y la demanda real real en azul, los puntos rojos son las anomalías que detectó el algoritmo. El total de anomalías detectadas fue igual a 1744 mientras que al conjunto de testeo solo fueron imputadas un total de 897 anomalías de cuatro tipos distintos.

Cuadro 2: Resultados por Tipo de Anomalías

Métricas	Tipo de anomalía			
	Tipo 1	Tipo 2	Tipo 3	Tipo 4
<i>Recall</i>	1.0	0.3644	0.0	0.25

Fuente: Elaboración propia.

A partir de los resultados del Cuadro 2, se observa que la anomalía tipo 1, correspondiente a una disminución abrupta de la energía, y tipo 2, cuando la energía se estanca por unos

periodos de tiempo, fueron las que mejor supo detectar, mientras que no supo identificar con exactitud las anomalías relacionadas a un aumento en el consumo de energía, el tipo 3 y 4. Los resultados obtenidos no fueron muy alentadores, confundiéndose mucho entre los altos valores de consumo, pero que siguen estando dentro de los parámetros normales de consumo, y los picos de consumo en un determinado tiempo que son realmente anomalías, y por ello solamente reportó de forma correcta el 36 % del total de anomalías.

8. Conclusiones Preliminares

El objetivo de este trabajo fue indagar sobre la capacidad de una red neuronal Long-Short Term Memory para predecir la demanda de energía eléctrica del Mercado Energético Mayorista de Argentina considerado como el punto de encuentro entre la oferta y la demanda de energía eléctrica en tiempo real, disperso a lo largo del país, con su estructura y todas sus particularidades, que no son las mismas que los mercados estudiados en los trabajos que fueron referenciados para realizar este trabajo, donde la liberación del mercado si fue total y la urgencia venía del lado de poder predecir la volatilidad de los precios de la demanda de energía. En este caso encontramos que en la reforma que sufrió el sector energético en 1992 la liberación no fue total y la competencia surgió solamente en algunas partes de la cadena productiva del sector. Uno de los mayores cambios fue el surgimiento de una entidad responsable por el manejo y la coordinación de todo este sistema a través de una operación planificada para garantizar la generación óptima y confiable al menor costo posible tanto en el corto como en el largo plazo, la Compañía Administradora del Mercado Mayorista Eléctrico.

Como fue mencionado anteriormente, el carácter no estacionario de la demanda de energía eléctrica y su fuerte volatilidad debido al gran número de factores que influyen sobre la misma, desde cuestiones climáticas hasta económicas, la vuelven impredecible principalmente en el corto plazo, sobre todo en los momentos donde ocurren las famosas anomalías que del lado de la demanda en general se presentan por picos en su consumo. A través de proyectar la demanda y detectando sus posibles anomalías con anticipación a la ocurrencia de este tipo de hechos facilitaría esta coordinación que lleva a cabo CAMMESA entre la oferta y la demanda dentro del mercado, permitiéndole cumplir con un servicio de calidad y al menor costo posible.

En virtud del alto rendimiento presentado por la red LSTM que fue propuesta en este trabajo, se concluye que este método no solo es válido para realizar proyecciones de la demanda en un mercado de estructura diferente a los mercados del resto del mundo, sino que también son una opción viable para una mejora en el desarrollo de las tareas de coordinación que se realizan constantemente CAMMESA en el MEM.

En cuanto al método de Nonparametric Thresholding, a pesar de los resultados, parece un algoritmo bastante prometedor para ponerlo a prueba e ir realizando ajustes para que se adapte al resto del tipo de anomalías que se pueden presentar en la demanda real de energía.

Referencias

- Bakhtawar Shah, M. (2019). *Anomaly detection in electricity demand time series data*.
- Becker, E. (2020). *Análisis del mercado eléctrico argentino. impacto de la regulación en su funcionamiento*. Universidad Nacional del Sur.
- Burmingham, I. (2021). *multivariate-time-series-anomaly-detection*. Descargado de <https://github.com/Isaacburningham/multivariate-time-series-anomaly-detection>
- Feijoo, F., Silva, W., y Das, T. K. (2016, 04). A computationally efficient electricity price forecasting model for real time energy markets. *Energy Conversion and Management*, 113, 27-35. doi: 10.1016/j.enconman.2016.01.043
- Hundman, K., Constantinou, V., Laporte, C., Colwell, I., y Soderstrom, T. (2018). *Detecting spacecraft anomalies using lstms and nonparametric dynamic thresholding*.
- Jamil, F. (2013). On the electricity shortage, price and electricity theft nexus. *Energy policy*, 54, 267–272.
- Lin, W.-M., Gow, H.-J., y Tsai, M.-T. (2010, 12). Electricity price forecasting using enhanced probability neural network. *Energy Conversion and Management*, 51, 2707-2714. doi: 10.1016/j.enconman.2010.06.006
- Mahjoub, S., Chrifi-Alaoui, L., Marhic, B., y Delahoche, L. (2022, 05). Predicting energy consumption using lstm, multi-layer gru and drop-gru neural networks. *Sensors*, 22, 4062. doi: 10.3390/s22114062
- Malhotra, P., Vig, L., Shroff, G., y Agarwal, P. (2015). *Long short term memory networks for anomaly detection in time series*. (Vol. 2015).
- Mir, A. A., Alghassab, M., Ullah, K., Khan, Z. A., Lu, Y., y Imran, M. (2020, 07). A review

- of electricity demand forecasting in low and middle income countries: The demand determinants and horizons. *Sustainability*, 12, 5931. doi: 10.3390/su12155931
- Shah, I., Iftikhar, H., Ali, S., y Wang, D. (2019, 07). Short-term electricity demand forecasting using componentsestimation technique. *Energies*, 12, 2532. doi: 10.3390/en12132532
- Stábile, F. (2011). *Evolución del mercado eléctrico mayorista argentino. impacto de los subsidios en la gestión y en los resultados* (Tesis Doctoral no publicada).
- Turowski, M., Weber, M., Neumann, O., Heidrich, B., Phipps, K., Çakmak, H. K., ... Hagenmeyer, V. (2022). *Modeling and generating synthetic anomalies for energy and power time series*.
- Ziel, F., y Steinert, R. (2018, 10). Probabilistic mid- and long-term electricity price forecasting. *Renewable and Sustainable Energy Reviews*, 94, 251-266. doi: 10.1016/j.rser.2018.05.038